

IIR

INGÉNIERIE INFORMATIQUE & RÉSEAUX

ANNÉE UNIVERSITAIRE

2023/2024

OPTION

MÉTHODES INFORMATIQUES APPLIQUÉES
À LA GESTION DES ENTREPRISES (MIAGE)

PROJET DE FIN D'ÉTUDES

THÈME

Conception et réalisation d'un chatbot RAG
à l'aide de Langchain et Chromadb.

RÉALISÉ PAR

Douaibi Mostafa

ENCADRÉ PAR

NADIRI Abdeljalil

NOUHAS Soufiane & ELFEDDI Mustapha

SOUTENU LE

Dédicace

À mes parents adorés, pour l'amour sans limites que vous m'avez prodigué, votre patience inébranlable, et votre soutien inconditionnel à chaque étape de mon parcours. Votre confiance en moi a été le socle de ma détermination, et c'est grâce à vous que j'ai pu réaliser ce projet. À ma famille, pour votre présence rassurante, vos encouragements constants, et votre capacité à toujours trouver les mots justes pour me redonner espoir. Vous avez été ma boussole dans les moments d'incertitude. À mes amis, pour les éclats de rire, les conseils avisés, et les moments de répit que nous avons partagés. Votre soutien a été une bouffée d'air frais dans cette aventure, et je vous en suis profondément reconnaissant. À mes professeurs, pour votre passion pour l'enseignement et votre engagement à m'accompagner tout au long de mon parcours. Votre guidance et vos encouragements ont été une source d'inspiration inestimable. À tous ceux qui ont croisé mon chemin, je vous dédie ce travail en témoignage de ma gratitude. Chacun de vous a, à sa manière, contribué à ce que je devienne la personne que je suis aujourd'hui.

Remerciements

Tout d'abord, je tiens à exprimer ma profonde gratitude à Allah, qui m'a doté de l'intelligence et m'a préservé en bonne santé tout au long de ces années d'études. Je souhaite également remercier sincèrement tous les membres de l'équipe Custom Apps de DXC Maroc, et tout particulièrement M. Mustapha EL FEDDI et M. Soufiane NOUHAS. Leur confiance en moi, ainsi que leur partage généreux de connaissances, ont été d'une aide précieuse tout au long de mon parcours professionnel. Je tiens aussi à exprimer mes vifs remerciements à l'ensemble du personnel du siège de DXC Technology au Maroc, qui m'a accueilli chaleureusement durant mon stage. Grâce à eux, j'ai eu l'opportunité de découvrir et de participer à la vie quotidienne d'une équipe dynamique, rigoureuse et d'une grande convivialité.

Mes remerciements vont également aux responsables et aux enseignants de l'EMSI Marrakech. Leur patience, leur dévouement, et le temps précieux qu'ils ont consacré à notre formation en tant qu'ingénieurs sont inestimables. Je tiens à exprimer ma reconnaissance particulière à Monsieur NADIRI Abdeljalil pour ses conseils éclairés, son encadrement de qualité, et le soutien qu'il m'a apporté tout au long de l'élaboration de ce rapport.

Enfin, je remercie chaleureusement les honorables membres du jury pour avoir accepté de consacrer leur précieux temps à l'évaluation de ce travail.

Résumé

Ce projet de fin d'études a porté sur la conception et le développement d'un chatbot intelligent basé sur la technologie RAG (Retrieval-Augmented Generation). L'objectif principal était de créer un système capable de répondre de manière pertinente et contextuelle aux questions des utilisateurs en utilisant des documents PDF comme source d'information. Pour ce faire, le projet a intégré plusieurs technologies modernes, notamment LangChain pour la gestion des chaînes de traitement, ChromaDB pour le stockage et la recherche vectorielle des documents, et Flask pour l'implémentation du backend.

L'application se divise en plusieurs composants clés : un backend robuste gérant l'authentification des utilisateurs, le stockage des fichiers, et l'exécution des modèles d'intelligence artificielle ; une base de données vectorielle permettant une récupération rapide et précise des informations ; et enfin, un frontend intuitif, développé en React pour l'interface web, et en Tkinter pour l'application desktop, offrant une expérience utilisateur fluide.

Le chatbot est conçu pour non seulement fournir des réponses basées sur les documents stockés, mais aussi pour maintenir un contexte conversationnel, permettant ainsi une interaction plus naturelle et utile avec l'utilisateur. Grâce à l'intégration d'un modèle OCR, l'application est également capable d'extraire et d'analyser du texte à partir de fichiers PDF, enrichissant encore plus la capacité de récupération d'informations.

Le résultat final est une application complète et performante qui répond aux besoins des utilisateurs en matière de gestion de documents et de recherche d'informations, tout en offrant une expérience utilisateur intuitive et moderne. Ce projet démontre non seulement la faisabilité technique du concept, mais aussi son potentiel pour des applications pratiques dans divers domaines professionnels.

Mots clés : PFE, RAG, LANGCHAIN, CHROMADB.

Abstract

This final year project focused on the design and development of an intelligent chatbot based on RAG (Retrieval-Augmented Generation) technology. The primary objective was to create a system capable of providing relevant and contextual answers to user queries using PDF documents as the source of information. To achieve this, the project integrated several modern technologies, including LangChain for chain management, ChromaDB for document storage and vector search, and Flask for backend implementation.

The application is divided into several key components: a robust backend managing user authentication, file storage, and the execution of artificial intelligence models; a vector database allowing for rapid and precise information retrieval; and finally, an intuitive frontend, developed in React for the web interface, and Tkinter for the desktop application, offering a smooth user experience.

The chatbot is designed not only to provide answers based on stored documents but also to maintain conversational context, enabling a more natural and useful interaction with the user. With the integration of an OCR model, the application is also capable of extracting and analyzing text from PDF files, further enhancing its information retrieval capabilities.

The final result is a complete and high-performance application that meets users' needs for document management and information retrieval while offering an intuitive and modern user experience. This project demonstrates not only the technical feasibility of the concept but also its potential for practical applications in various professional fields.**

Keywords: Final Year Project, RAG, LangChain, ChromaDB.

Glossaire

CDG	: Caisse de dépôt et de gestion
CLN	: Column Networks
CNN	: Convolutional Neural Network
CSC	: Computer Sciences Corporation
DXC	: Delivering eXcellence for our Customer and colleagues
FFN	: Feedforward Neural Network
GAN	: Generative Adversarial Network
HP	: Hewlett Packard
HPE	: Hewlett Packard Enterprise
HTML	: Hypertext Markup Language
CSS	: Cascading Style Sheets
MY SQL	: My Structured Query Language
IA	: Intelligence Artificielle
IT	: Information Technology
JWT	: JSON Web Token
LLM	: Large Language Model
LSTM	: Long Short-Term Memory
ML	: Machine Learning
OCR	: Optical character Recognition
PDF	: Portable Document Format
RAG	: Retrieval Augmented Generation
RNN	: Recurrent Neural Network
TLN	: Transfer Learning Language
UML	: Unified Modeling Language

Table des matières

Dédicace.....	I
Remerciements.....	II
Résumé	III
Abstract.....	IV
Glossaire	V
Introduction Générale.....	1
Chapitre I :	2
CONTEXTE GENERAL DU PROJET	2
I. Introduction	3
II. Présentation du Groupe DXC Technology :.....	3
1. <i>DXC Technology Monde</i>	3
II. Etude générale du projet :.....	8
III. Conclusion.....	19
Chapitre II :	20
Revue de la littérature	20
I. Introduction	21
II. L'Intelligence artificielle générative :.....	21
1. <i>Définition</i>	21
2. <i>Fonctionnement de l'intelligence artificielle générative</i>	21
III. Large Language Model :.....	23
1. <i>Définition</i>	23
2. <i>L'essor de Large Language Model</i>	24
3. <i>Modèle de transformateur</i>	24
4. <i>Principaux composants de LLM</i>	25
5. <i>Les différents types de LLM</i>	25
6. <i>Fonctionnement de LLM</i>	26
7. <i>Cas d'utilisation des LLM</i>	27
8. <i>Limites de LLM</i>	28
IV. Retrieval-augmented generation :.....	28
1. <i>Définition</i>	28
2. <i>Comment fonctionne le Retrieval-augmented generation ?</i>	28
3. <i>Loader et Splitter</i>	29

4.	<i>Embedding</i>	30
5.	<i>Vector Store</i>	30
6.	<i>Retrieval</i>	31
7.	<i>Avantages et risques d'utilisation d'un Retrieval- augmented generation</i>	32
8.	<i>Fine-Tuning</i> :	32
V.	<i>Conclusion</i> :.....	33
Chapitre III : Analyse et		34
Conception du projet		34
I.	<i>Introduction</i> :.....	35
II.	<i>Analyse</i> :	35
1.	<i>Identification des acteurs</i> :	35
2.	<i>Identification des besoins</i> :	36
III.	<i>Diagrammes</i>	37
1.	<i>Diagramme Cas d'utilisation</i> :.....	37
2.	<i>Diagramme de Séquence</i>	38
3.	<i>Diagramme de composants</i>	41
IV.	<i>Conclusion</i> :.....	42
Chapitre IV : Langages et outils utilisés		43
I.	<i>Introduction</i> :.....	44
II.	<i>Benchmarking</i> :	44
1.	<i>Choix du Framework</i> :	44
2.	<i>Justification du choix du Retrieval augmented generation</i> :	44
3.	<i>Choix du Large Model Language</i>	45
4.	<i>Choix du Base de données vectorielles</i>	45
5.	<i>Choix du Model d'ocr</i>	46
6.	<i>Choix du Model d'embedding</i>	46
1.	<i>Outils, langage, Technologies et Architecture logicielle</i> :	47
2.	<i>Architecture logicielle</i> :	51
3.	<i>Architecture applicative</i> :	52
III.	<i>Conclusion</i> :.....	54
Chapitre V : Réalisation		56
I.	<i>Introduction</i>	57
II.	<i>Backend</i>	57

1. Prétraitement des Données.....	58
III. 2. Frontend - Application Desktop (Tkinter).....	63
IV. 3. Frontend - Application Web (React)	65
V. Conclusion.....	69
Conclusion Générale	70
Annexe.....	71
I. Annexe1 : modèle OcR.....	71
• Introduction au CNN.....	71
• Dataset.....	71
• Prétraitement.....	71
• Mon CNN	72
• Évolution de l'Accuracy du Modèle.....	72
Références.....	73

Liste des Figures

Figure 1: Logo de HP-CDG IT Services Maroc	4
Figure 2 : Logo de DXC Technology.....	4
Figure 3 : Principaux services de DXC Technology Maroc	6
Figure 4 : Partenaires de DXC Technology Maroc.....	6
Figure 5 : Partenaires de DXC Technology Maroc.....	7
Figure 6 : Certificats de DXC Technology Maroc.....	7
Figure 7 : Extrait d'organigramme du DXC Technology Maroc	8
Figure 8 : Méthodologie Scrum.....	13
Figure 9 : Equipe Scrum	15
Figure 10 : Diagramme de gant.....	18
Figure 11 : Historique de LLM.....	24
Figure 12 : Architecture d'un Système RAG pour Q/R.....	29
Figure 13 : Analyse des Tokens et des Caractères des Textes du Journal Le Monde.....	30
Figure 14 : Représentation vectorielle des relations sémantiques	31
Figure 15 : Flux de Travail des Magasins de Vecteurs.....	31
Figure 16 : Diagramme de cas d'utilisation d'utilisateur.....	38
Figure 17 : Diagramme de séquence du système RAG du chatbot.....	39
Figure 18 : Diagramme de composants	41
Figure 19 : Architecture de déploiement	51
Figure 20 : Architecture applicative.....	52
Figure 21 : Illustration de la procédure	54
Figure 22 : Backend API Endpoints	57
Figure 23 : Extrait d'un document de test	58
Figure 24 : Vector Database (ChromaDB) Metadata.....	60
Figure 25 : LLMChain and RetrievalQA Execution Trace.....	60
Figure 26 : Retriever Execution and Document List.....	61
Figure 27 : ChatOpenAI Execution Trace	62
Figure 28 : Écran de Connexion de l'Application Desktop.....	63
Figure 29 : Écran Principal de l'Application Desktop.....	63
Figure 30 : Écran de Confirmation de Téléchargement	64
Figure 31 : Écran de Connexion de l'Application Web.....	65
Figure 32 : Écran de Création de Compte de l'Application Web.....	65
Figure 33 : Écran d'Accueil de l'Application Web.....	66
Figure 34 : Écran de Gestion des PDF avec OCR (Application Desktop)	66
Figure 35 : Écran de Téléchargement de PDF ou Texte	67
Figure 36 : Écran d'Interaction avec le Chatbot (Application Web).....	67
Figure 37 : Écran de Navigation et Extraction OCR du PDF (Application Web).....	68

Liste des Tables

Tableau 1 : Fiche technique DXC Technology Maroc	5
Tableau 2 : Tableaux de Gestion des Risques.....	11
Tableau 3 : User Stories	16

Introduction Générale

Dans un monde où les données sont omniprésentes, la capacité à interagir de manière efficace avec des systèmes d'information complexes devient cruciale. Le développement de solutions basées sur l'intelligence artificielle, telles que les chatbots, s'inscrit dans cette dynamique. Ces technologies permettent de fournir des réponses rapides et pertinentes aux utilisateurs, tout en s'adaptant au contexte spécifique de chaque interaction. Ce rapport présente le travail réalisé dans le cadre de mon projet de fin d'études, qui a consisté à concevoir et développer un chatbot intelligent basé sur la technologie RAG (Retrieval-Augmented Generation).

L'objectif principal de ce projet est de créer un système capable de répondre de manière contextuelle et précise aux questions des utilisateurs, en utilisant des documents PDF comme source d'information. Pour atteindre cet objectif, plusieurs technologies modernes ont été intégrées, notamment LangChain pour la gestion des chaînes de traitement, ChromaDB pour le stockage et la recherche vectorielle des documents, et Flask pour l'implémentation du backend. L'application développée est structurée en plusieurs composants clés, allant d'un backend robuste à un frontend intuitif, chacun jouant un rôle crucial dans l'efficacité et la fluidité du système.

Le rapport est organisé en cinq chapitres principaux. Le premier chapitre, **Contexte Général du Projet**, expose les motivations du projet, ses objectifs, ainsi que l'environnement dans lequel il s'inscrit. Le deuxième chapitre, **Revue de la Littérature**, offre un panorama des technologies et des approches existantes en matière de chatbots et de gestion d'information, afin de situer le projet dans un contexte théorique plus large. Le troisième chapitre, **Analyse et Conception du Projet**, détaille la méthodologie adoptée pour concevoir le système, avec une attention particulière portée à l'analyse des besoins fonctionnels et non fonctionnels. Le quatrième chapitre, **Langages et Outils Utilisés**, présente les technologies et outils choisis pour le développement du projet, en expliquant les raisons de ces choix. Enfin, le cinquième chapitre, **Réalisation**, décrit en détail le processus de développement de l'application, de l'implémentation des différents modules à l'intégration finale du système.

Ce rapport vise à démontrer la faisabilité technique du concept proposé et à illustrer son potentiel pour des applications pratiques dans divers domaines professionnels. Au-delà des aspects techniques, il met également en lumière les défis rencontrés et les solutions apportées, offrant ainsi une vision complète du projet réalisé.

Chapitre I :
CONTEXTE GENERAL DU PROJET

I. Introduction

Dans ce chapitre, nous plongeons dans le contexte global qui a donné naissance à ce projet. Nous commencerons par présenter l'entreprise dans laquelle le projet a été mené, mettant en lumière son domaine d'activité, sa mission, et son positionnement sur le marché. Ensuite, nous nous pencherons sur le projet lui-même, en détaillant son objectif, sa portée, et les défis qu'il vise à résoudre. Cette exploration du contexte général nous permettra de mieux comprendre les enjeux et les motivations sous-jacents à la réalisation de ce travail.

II. Présentation du Groupe DXC Technology :

1. DXC Technology Monde

DXC Technology est une société américaine de conseil et de services informatiques cotée en bourse issue de la fusion en 2017 de CSC et de la division Enterprise Services de HPE. La nouvelle société, qui générera des ventes annuelles de 20 milliards de dollars américains avec près de 6.000 clients et 130.000 personnes dans plus de 70 pays dans les 5 continents de l'Europe, l'Amérique, l'Afrique et l'Asie et se décrit comme étant le plus grand fournisseur indépendant de services informatiques de bout en bout au monde avec plus de 60 années d'innovation dans la fourniture de systèmes critiques pour les clients. En tant qu'employeur, DXC est très respecté dans le secteur informatique et prône des valeurs fortes axées sur l'inclusion, l'appartenance et la citoyenneté d'entreprise.

L'entreprise fournit des Services IT dont les clients ont besoin pour moderniser leurs opérations et stimuler l'innovation dans l'ensemble de leur parc IT. DXC Technology aide ses collaborateurs et clients à créer une expérience de travail riche, à simplifier et à optimiser l'IT sur site, et à obtenir un environnement Cloud sécurisé et performant pour obtenir des résultats business positifs. Les services tissent la cyber-résilience dans toute l'entreprise, aident les clients à réimaginer l'activité avec des applications transformatrices, et permettent des décisions fondées sur les données, l'automatisation et l'ingénierie de pointe, l'externalisation des processus métier de DXC aide les clients à transformer leurs opérations en un modèle d'entreprise digitale.

La multinationale de technologie fournit des services informatiques de classe mondiale à grande échelle à partir de ses centres mondiaux d'innovation et de livraison en Amérique du Nord, en Amérique du Sud, en Europe, en Asie et en Australie. Les centres connectés à l'échelle mondiale permettent de résoudre des défis technologiques complexes et de transformer les activités des clients grâce à un personnel de livraison dédié de plus de 110.000 personnes.

Avec des équipes réparties dans le monde entier et de riches compétences en ingénierie, DXC propose des solutions compétitives pour répondre aux exigences des clients en matière de coût, de réglementation, de langue et de continuité des activités pour tirer parti de la puissance des partenariats grâce à l'écosystème DXC organisé de leaders technologiques. En combinant ses forces et son expertise à l'échelle mondiale, DXC Technology crée des solutions et offre les meilleurs résultats aux clients de l'ensemble de la Stack de technologie d'entreprise.

1.1 DXC Technology Maroc

HP-CDG IT Services Maroc est le fruit d'un partenariat stratégique entre HPE, leader mondial du marché IT et CDG.



Figure 1: Logo de HP-CDG IT Services Maroc

Depuis sa création en 2007, HP-CDG IT Services Maroc s'est rapidement positionnée parmi les leaders du conseil, des services informatiques et de l'infogérance en capitalisant sur l'expertise de renommée mondiale de HP. L'entreprise développe une vaste gamme de conseils, de solutions et de services technologiques. En 2017, la dénomination de l'entreprise a été modifiée pour devenir DXC Technology au Maroc suite à un partenariat entre DXC Technology et la CDG. Cette nouvelle appellation a été effective le 3 avril 2017, date de la création de DXC Technology résultant de la fusion entre HPE et CSC.



Figure 2 : Logo de DXC Technology

1.1.1 Fiche signalétique

Dans cette sous-section, la fiche signalétique de la société DXC Technology est présentée dans le tableau suivant :

Dénomination sociale	DXC Technology
Date de création	1 ^{er} Juillet 2007
Actionnaires	DXC Technology (51 %), CDG (49 %)
Forme juridique	Joint-Venture
Capital	22 270 000 DHS
Chiffre d'affaires	400 millions de dirhams
Activités	Services informatiques, Infogérance, Offshoring, Analytics and Engineering, Applications, Cloud, Consulting, Insurance BPaaS and BPO, IT Outsourcing, Modern Workplace, Security
Effectif	Entre 1 001-5 000 employés
Dirigeant	Mehdi Kettani (CEO)
Coordonnées	- Adresse : Bâtiment B9, Technopolis, 11 100, Sala Al Jadida - Maroc - Téléphone : 0530-576400 - Site Web : https://www.dxc.technology/

Tableau 1 : Fiche technique DXC Technology Maroc

1.1.2 Missions et Services

DXC propose une gamme complète de services pour aider les entreprises à être disruptives, à se réinventer et à développer de nouvelles agilités. L'entreprise accompagne également les projets depuis la stratégie jusqu'à l'implémentation et considère le changement comme un catalyseur de réussite grâce à sa devise "hrive On Change".

DXC Technology au Maroc se concentre sur l'accompagnement des grandes entreprises et des

donneurs d'ordre publics et privés dans leur transformation numérique. Avec plus de 50 clients locaux et offshore, DXC Technology est un partenaire de confiance pour les entreprises qui cherchent à se développer sur le marché numérique.




Figure 3 : Principaux services de DXC Technology Maroc

1.1.3 Partenaires de l'entreprise DXC Technology

Actuellement, les partenaires locaux de DXC sont des entreprises de grands comptes opérant dans différents marchés et domaines multidisciplinaires dans :



Figure 4 : Partenaires de DXC Technology Maroc



Figure 5 : Partenaires de DXC Technology Maroc

Les partenaires ont choisi de faire confiance à DXC Technology en raison de ses nombreuses certifications attestant de sa compétence dans plusieurs catégories couvrant l'ensemble des industries susmentionnées. Parmi les certifications les plus reconnues, on peut citer :



Figure 6 : Certificats de DXC Technology Maroc

1.1.4 Organigramme DXC Technology

Mon stage s'est déroulé au sein de la division CTO Apps de DXC Technology Maroc, située à Rabat. Cette unité est intégrée aux Global Business Service de l'entreprise, se focalisant sur les applications personnalisées et les solutions d'entreprise. CTO Apps est gérée par Monsieur Mustapha el Feddi, Directeur des Nouvelles Technologies chez DXC Technology au Maroc, il a également été mon encadrant durant cette période, me fournissant un accompagnement et une supervision directe tout au long de mon stage.

Tout au long de mon expérience, j'ai constaté que CTO Apps joue un rôle essentiel dans l'adaptation et la mise en place de solutions technologiques avancées afin de satisfaire les besoins particuliers des clients. Un extrait de l'organisation globale de DXC Technology est présenté dans l'organigramme ci-joint, qui met en évidence la structure des services Global Business et Global Infrastructure Services, où se trouve CTO Apps. Il convient de souligner que l'organisation de cet organigramme pourrait être modifiée afin d'optimiser les flux de travail et de renforcer l'efficacité opérationnelle au sein de l'entreprise.

Cette évolution témoigne de l'engagement de DXC Technology envers l'innovation constante et l'amélioration de ses services afin de mieux satisfaire les exigences du marché et les besoins de sa clientèle.




Figure 7 : Extrait d'organigramme du DXC Technology Maroc

//. Etude générale du projet :

1. Périmètre du projet

1.1 Problématique générale

Actuellement, il n'existe pas de solution efficace pour la conversation interactive avec les fichiers PDF. Jusqu'à maintenant, les méthodes employées reposent fréquemment sur des processus manuels et disparates, obligeant les utilisateurs à fouiller de nombreux fichiers PDF pour trouver les informations requises. Faire face à des défis en matière d'efficacité, de précision et de rapidité dans l'accès aux données cruciales est traditionnellement abordé d'une certaine manière.

Le principal défi de ce projet est de créer un chatbot spécialisé capable d'interpréter les demandes des utilisateurs en langage naturel, d'extraire les informations pertinentes à partir des fichiers PDF et de fournir des réponses précises et contextualisées. L'objectif est de créer une solution innovante qui simplifie la navigation dans des documents PDF complexes et encourage une conversation interactive plus efficace avec les ressources requises.

2. Solutions Proposées :

Dans le cadre de mon projet de fin d'études, plusieurs solutions innovantes sont envisagées pour améliorer la gestion et l'interprétation des documents en PDF au sein de l'entité légale de l'entreprise. Un Q&A Bot basé sur le cloud Azure est la première option, en utilisant Azure Cognitive Search et Form Recognizer pour traiter efficacement les PDF. Avec cette solution, il est facile de s'intégrer avec d'autres services, de bénéficier d'un bon support et de respecter les normes de sécurité et de confidentialité. Néanmoins, elle dépend d'un service cloud externe et peut entraîner des coûts élevés en fonction de son utilisation. La deuxième option implique de mettre en place un Q&A basé sur un système de Fine-tuning. Pour cette méthode, on utilise des modèles pré-entraînés affinés sur des données spécifiques. Cependant, si le modèle est excessivement adapté aux données spécifiques de l'entraînement, Il pourrait perdre sa capacité à généraliser et à répondre de manière adéquate à de nouvelles questions ou à des situations légèrement différentes. De plus, il est souvent indispensable de prendre en charge et de partager des données potentiellement sensibles, ce qui complique l'assurance de la confidentialité et de la sécurité des données.

Enfin, la troisième option que nous favorisons est de mettre en place un Q&A basé sur un système RAG. Grâce à cette solution, la gestion locale des vecteurs est combinée avec des capacités avancées de réponse pour des réponses précises et personnalisées, assurant ainsi une meilleure confidentialité. Sa flexibilité et sa personnalisation élevées lui confèrent un excellent service, ce qui lui permet de répondre rapidement et efficacement aux questions spécifiques, comblant parfaitement les besoins complexes de notre entité.

3. Objectifs du Projet

Le projet comporte plusieurs objectifs clés qui sont indispensables pour son succès :

- **Gain de temps et efficacité :** Développer un chatbot capable d'effectuer rapidement et efficacement des tâches de traitement de fichiers PDF, permettant ainsi aux utilisateurs de gagner du temps dans leurs recherches et leurs analyses, tout en améliorant leur productivité globale.
- **Automatisation des processus :** Mettre en place des fonctionnalités d'automatisation qui permettent au chatbot de rechercher et d'identifier automatiquement les points clés dans les documents PDF, réduisant ainsi le besoin d'intervention manuelle et accélérant le processus de recherche d'informations.
- **Productivité accrue :** Faciliter la productivité en réduisant le temps passé à parcourir de longs documents PDF, permettant ainsi aux utilisateurs de se concentrer sur des tâches plus importantes et stratégiques dans leur travail quotidien.
- **Convivialité et facilité d'utilisation :** Concevoir une interface conviviale pour le chatbot, offrant aux utilisateurs une expérience agréable et intuitive lors de l'interaction avec les fichiers PDF, ce qui facilite l'accès aux informations nécessaires et encourage leur utilisation continue.
- **Disponibilité continue :** Assurer la disponibilité 24 heures sur 24 et 7 jours sur 7 du chatbot, permettant aux utilisateurs d'accéder et de traiter leurs fichiers PDF à tout moment et depuis n'importe où, ce qui augmente leur flexibilité et leur efficacité dans leur travail quotidien.

4. Registre de Gestion des Risques

Le “Registre de Gestion des Risques” sera créé et maintenu par le chef de projet décrivant les risques de toutes natures pouvant affecter la bonne réalisation du projet et détaillant leur probabilité de réalisation et la sévérité des impacts sur le projet. L’objectif de cette procédure de gestion des risques est d’en maîtriser autant que possible les effets et de permettre la définition et la mise en œuvre de mesures visant à en limiter les effets.

Réf	Description	Impacts	Type	Poids	Actions préventives	Etat
R01	Confidentialité et sécurité des données	Violation de la vie privée, perte de confiance	Confidentiel	Sévère	Cryptage des données sensibles, Gestion stricte des autorisations d'accès	À évaluer
R02	Qualité des données	Pertinence et la fiabilité des réponses du chatbot	Opérationnel	Sévère	Mise en place de contrôles de qualité, Tests réguliers des données	En cours
R03	Exactitude des réponses	Crédibilité et l'efficacité du chatbot	Opérationnel	Sévère	Utilisation d'algorithmes spécialisés, Vérifications manuelles régulières	À évaluer
R04	Maintenance et évolutivité	Dysfonctionnement et d'obsolescence du chatbot à long terme	Maintenance	Moyen	Planification régulière des mises à jour, Allocation de ressources dédiées	À évaluer

Tableau 2 : Tableaux de Gestion des Risques

5. Acteurs

Pour notre projet visant à aider l'entité utilisatrice de l'entreprise, quatre acteurs principaux jouent des rôles cruciaux :

- **AI Spécialistes** : Encadrement technique du projet, définition des tâches spécifiques liées à l'intelligence artificielle, et contrôle global des réalisations. L'AI Specialist est responsable de s'assurer que les solutions techniques répondent aux besoins spécifiés et maintiennent les normes de qualité.

- **Entité utilisatrice :** Utilisateurs finaux de l'application. Ce groupe teste et utilise le chatbot dans leur travail quotidien pour gérer les informations contenues dans les documents PDF. Ils fournissent des retours essentiels pour l'ajustement et l'amélioration de l'outil.
- **CTO Apps :** Sponsor du projet et responsable de la définition initiale du besoin. Le CTO Apps joue un rôle clé dans l'approbation des étapes clés du projet et dans la fourniture des ressources nécessaires.
- **Service Line Custom Apps :** Responsable de la validation du projet. Ce groupe s'assure que le chatbot est en alignement avec les autres applications et services proposés par l'entreprise, et que son intégration se fera sans perturber les processus existants.

6. Déroulement du projet

6.1 Méthodologie Scrum

La méthodologie Scrum a été choisie pour la réalisation de notre projet, en raison de la nécessité d'avoir une vision globale de la solution à mettre en place. Cette vision englobe les aspects techniques, architecturaux et fonctionnels du projet. De plus, notre projet est décrit par des phases clés lors de son développement, avec des besoins clients qui se concrétisent au fur et à mesure de la réalisation. Ces besoins ne peuvent pas être entièrement fixés à l'avance par une modélisation initiale, ce qui rend la flexibilité de la méthodologie agile indispensable.

La méthode agile permet une vérification fonctionnelle tout en recueillant les nouveaux besoins au fil du développement. Cette adaptabilité est essentielle pour répondre à l'extensibilité de la solution dans le temps et à la demande de nouvelles fonctionnalités. De plus, étant donné que la méthodologie agile était également la méthode demandée par l'entreprise, nous étions dans l'obligation de respecter les consignes de notre employeur et de travailler dans ce cadre.

Ainsi, en utilisant la méthodologie Scrum, nous sommes en mesure de répondre de manière efficace et flexible aux besoins évolutifs du projet tout en assurant une vérification fonctionnelle continue et en recueillant les retours d'expérience des parties prenantes.




Figure 8 : Méthodologie Scrum

Le processus Scrum, rigoureusement organisé, guide chaque étape du développement de manière efficace et collaborative :

- **Carnet de produit :** Le Product Owner façonne la direction du projet en rédigeant les User Stories et en les classant dans le Product Backlog. Ces histoires sont ensuite priorisées, permettant ainsi de structurer le backlog en fonction des besoins et des objectifs.
- **Réunion de planification de sprint :** L'équipe Scrum se réunit pour définir les objectifs du Sprint en sélectionnant les User Stories à traiter. Ces histoires deviennent le Sprint Backlog, qui sera ensuite décomposé en tâches gérables par l'équipe de développement.
- **Début de Sprint :** Avec les objectifs clairement définis, le Sprint démarre, généralement pour une période de deux semaines, permettant à l'équipe de se concentrer sur les tâches identifiées.
- **Mêlée quotidienne :** Chaque jour, l'équipe se rassemble pour la Mêlée quotidienne, un moment crucial pour synchroniser les actions, résoudre les blocages potentiels et ajuster les plans en fonction des besoins.
- **Fin de sprint :** À la fin du Sprint, le travail accompli est présenté lors de la revue du Sprint, mettant en lumière les réalisations et les éventuelles améliorations à apporter.
- **Rétrospective de Sprint :** Le cycle se conclut par la rétrospective de Sprint, offrant à l'équipe l'opportunité de réfléchir sur son fonctionnement, d'identifier les réussites et les défis, et de mettre en place des actions d'amélioration continue pour le prochain Sprint.

Ce processus itératif permet à l'équipe de Scrum de s'adapter rapidement aux changements, de livrer de la valeur de manière régulière et d'améliorer continuellement son travail.

6.2 Progression agile : Planification des Sprints

La planification du sprint est un événement Scrum qui met en place le début du sprint. Son but est de déterminer les objectifs à atteindre lors du sprint et de déterminer la manière d'y parvenir. En collaboration avec toute l'équipe Scrum, la planification du sprint est réalisée. Un sprint fait référence à une courte période de temps restreinte nécessaire à une équipe Scrum pour accomplir une tâche spécifique. Les sprints jouent un rôle essentiel dans les méthodes Scrum et Agile.

Notre projet a suivi une planification stratégique et méthodique, conformément aux principes de la méthodologie Agile. Le tableau suivant présente de manière explicite les tâches réalisées, les responsabilités assignées, les avancées réalisées et les échéances respectées, ce qui permet d'obtenir une transparence totale sur le déroulement du projet pendant la phase initiale de développement, qui s'étend du début de mon stage jusqu'à ma soutenance.

Dans la première phase, les bases nécessaires ont été établies et les principales fonctionnalités du Chatbot RAG ont été définies. Bien que cette étape de développement se termine avec ma présentation de la soutenance, le projet lui-même continuera à se développer au sein de l'entreprise avec une deuxième phase prévue. Je continuerai à apporter ma contribution à l'avancement de ce projet, en intégrant les améliorations repérées et en finalisant les fonctionnalités du chatbot afin de répondre de manière plus efficace aux besoins spécifiques de l'entité utilisatrice. Comme indiqué dans Annexe 1 et 2.

6.3 Phases du projet

La progression du projet s'articule autour de différentes phases clés :

- **Phase d'initialisation et de cadrage :** Cette étape initiale consiste à se familiariser avec le contexte métier de l'entreprise cliente et l'environnement du projet.
- **Étude technique et fonctionnelle :** Cette phase vise à établir l'infrastructure de travail, à organiser des réunions avec les parties prenantes et à rédiger les spécifications fonctionnelles. Les choix fonctionnels sont définis à travers un document de spécifications des besoins, résultant de l'analyse et des exigences du client.
- **Réalisation de l'application :** Cette étape représente la phase active du projet, où les spécifications définies précédemment sont mises en œuvre. Toutes les ressources

planifiées pendant la phase de conception sont mobilisées pour concrétiser le projet.

- **Mise en production de l'application** : Une fois les tests réalisés dans l'environnement de production, l'application est déployée. C'est à ce stade que le client peut commencer à utiliser pleinement l'application.

Cette structure permet une progression logique du projet, de sa conception initiale à sa mise en œuvre opérationnelle.

6.4 Equipe du projet

Le projet sera réalisé par un groupe de 3 stagiaires comme montré dans la figure 9, la méthode Scrum définit trois rôles qui sont :

- Le Product Owner (le propriétaire du produit) : c'est une personne qui porte la vision du produit à réaliser, généralement c'est un expert dans le domaine.
- Le Scrum Master (le directeur de produit) : c'est la personne qui doit assurer le bon déroulement des différents sprints du release, et qui doit impérativement maîtriser Scrum.
- La Scrum Team (l'équipe de Scrum) : constitué des personnes qui seront chargées d'implémenter les différents besoins du client. Bien évidemment, cette équipe sera constituée des développeurs, des infographistes et autres.




Figure 9 : Equipe Scrum

6.5 Users stories :

Les fonctionnalités à développer sont représentées par une user story. Une User story, ou récit utilisateur, est une description des exigences pour toutes les fonctionnalités ou les tâches indispensables au bon fonctionnement du produit ou du service en développement.

Tableau 3 : User Stories

Epic	User story	Tâches à effectuer	Critères d'acceptation
E1	En tant que utilisateur, je souhaite gérer les droits d'accès des différents membres de l'équipe pour garantir que les informations sensibles ne soient accessibles qu'au personnel autorisé.	Définir les rôles et permissions des utilisateurs dans le système. Développer un mécanisme de contrôle d'accès.	L'application doit supporter plusieurs rôles utilisateur avec différents niveaux d'accès. Les utilisateurs doivent pouvoir demander l'accès aux informations, qui doit être approuvé par un responsable.
E2	En tant que utilisateur, je souhaite que le chatbot puisse gérer des requêtes complexes impliquant plusieurs documents et retourner des réponses consolidées, permettant une recherche complète.	Développer une capacité de gestion de plusieurs documents dans le modèle RAG. Implémenter un module de réponse pour mettre en évidence les résultats clés pertinents.	Le chatbot doit être capable de traiter des requêtes couvrant plusieurs documents et retourner une réponse synthétisée. La réponse doit mettre en évidence les documents et les sections spécifiques où les informations ont été trouvées.

E3	En tant que utilisateur, je souhaite que le chatbot se souvienne de nos interactions passées afin de pouvoir poursuivre mon	Concevoir un schéma de base de données pour le stockage des interactions des utilisateurs.	Le chatbot doit conserver un historique de toutes les interactions pour chaque utilisateur.
----	---	---	--

	travail de manière fluide sur plusieurs sessions sans avoir à répéter ou rechercher des informations précédentes.	Implémenter la fonctionnalité pour récupérer et afficher l'historique des interactions.	Les utilisateurs doivent pouvoir visualiser, rechercher et référencer les interactions passées.
E4	En tant que utilisateur, je souhaite que le chatbot puisse rapidement extraire les informations d'une section spécifique des documents afin que je puisse consulter les informations pertinentes sans avoir à chercher manuellement dans chaque document.	Intégrer le modèle RAG pour générer des réponses basées sur le texte extrait. Implémenter de NLP pour interagir avec le texte PDF.	Le chatbot doit comprendre et interpréter les demandes concernant des sections spécifiques au sein des documents PDF.

6.6 Planification du projet




Figure 10 : Diagramme de gant

La planification est une étape fondamentale pour assurer le succès de tout projet. Elle consiste à

organiser les différentes tâches en fonction de leur importance, de leurs interdépendances et de leur durée, de manière à créer un plan de travail efficace pour atteindre les objectifs fixés.

Le projet était nouveau pour ma part, Il utilise des technologies non abordées le long de mon parcours scolaire. Du coup, une planification rigoureuse s'est imposée pour prévoir le déroulement du projet. Le stage a débuté le 05 mars pour une durée de 6 mois. Il en résulte le planning suivant :

III. Conclusion

En somme, ce chapitre a fourni une vue d'ensemble complète de notre projet, en exposant clairement ses objectifs, sa méthodologie pour structurer et gérer le projet, et détaillé les phases, la planification des sprints, ainsi que les users stories, et le cadre global dans lequel il s'inscrit. Ces éléments fournissent une vue d'ensemble essentielle pour comprendre la trajectoire que j'ai suivie pour atteindre nos objectifs. Cette étude constitue une base solide pour le bon déroulement et la réussite de notre projet.

Chapitre II :
Revue de la littérature

I. Introduction

Le présent chapitre propose une revue approfondie de la littérature en lien avec le projet de création d'un chatbot utilisant la méthode RAG pour une communication interactive avec des documents PDF. Nous explorerons les technologies clés impliquées, notamment l'intelligence artificielle générative et les modèles de langage à grande échelle (LLM), en soulignant leur rôle dans le développement de solutions de chatbot avancées.

II. L'Intelligence artificielle générative :

1. Définition

L'IA générative est une forme d'intelligence artificielle qui a la capacité de générer de nouveaux contenus et idées, tels que des échanges, des récits, des images, des vidéos et de la musique. Les technologies d'intelligence artificielle cherchent à reproduire l'intelligence humaine dans des domaines informatiques non conventionnels tels que la reconnaissance d'images, le traitement du langage naturel (NLP) et la traduction.

2. Fonctionnement de l'intelligence artificielle générative

En général, l'intelligence artificielle générative utilise des réseaux de neurones artificiels, notamment des modèles génératifs tels que les GAN :

- En premier lieu, de nombreuses données d'entraînement sont recueillies et préparées, ce qui constituera la fondation du modèle génératif. Par exemple, il peut s'agir de textes, d'images ou de vidéos.
- Le réseau neuronal est constitué de différentes couches. L'architecture précise varie en fonction du type de données à produire. On peut utiliser un modèle de réseaux neuronaux récurrents (RNN) pour les textes et des réseaux neuronaux convolutifs (CNN) pour les images.
- Le modèle de l'IA est utilisé pour analyser les données de formation et étudier comment il peut produire des données similaires. Il accomplit cela en modifiant les pondérations et les paramètres de ses neurones pour réduire au minimum les erreurs entre les données générées et les données d'entraînement réelles.

Après avoir été entraîné, le modèle peut être exploité pour produire de nouvelles données. Il n'y a qu'à donner au modèle une séquence ou une valeur de départ : c'est ce qu'on nomme une invite ou un prompt, qui peut être verbal, graphique ou dessiné. L'IA générative réagit en proposant de nouveaux contenus. Les données produites sont analysées pour garantir leur précision et leur pertinence. En le familiarisant avec de nouvelles informations, le modèle peut être constamment ajusté et perfectionné.

2.1 Applications de l'intelligence artificielle générative

L'intelligence artificielle générative peut être employée dans les domaines les plus variés, afin de produire presque toutes sortes de contenu. Des avancées révolutionnaires telles que GPT et la convivialité de la technologie rendent la technologie de plus en plus accessible. On peut citer parmi les domaines d'application de l'intelligence artificielle générative :

- Rédaction de textes : tels que des articles d'actualité, des textes créatifs, des emails, des CV, etc.
- Cinéma et animation : conception de personnages ou de scènes en images de synthèse, animées ou vidéo, etc.
- Pharmacie et chimie : découverte de nouvelles formes moléculaires ou de médicaments, amélioration de combinaison de composés chimiques.
- Chatbots : création de service client ou d'assistance technique.
- Formation : conception de vidéos de présentation de produits et de tutoriels dans diverses langues.

2.2 Les modèles de l'intelligence artificielle générative

Les modèles d'IA générative utilisent un réseau neuronal spécifique afin de produire de nouveaux contenus. En fonction des diverses utilisations, il peut s'agir de :

- Les réseaux adversaires génératifs (GAN) sont utilisés pour créer des images réalistes en utilisant un générateur et un discriminateur.
- Les réseaux neuronaux récurrents (RNNs) sont utilisés pour traiter des données séquentielles et sont spécialement adaptés à la production de texte ou de musique.
- Les modèles utilisant des transformateurs sont des modèles basés sur des transformateurs, comme GPT (Generative Pretrained Transformer) d'OpenAI, qui sont employés pour produire du texte.

- Les modèles basés sur le flux sont employés dans les applications sophistiquées afin de produire des images ou d'autres informations.
- Les encodeurs automatiques variables (VAE) sont fréquemment employés pour créer des images et des textes.

2.3 Préoccupations concernant l'intelligence artificielle générative

Il y a plusieurs inquiétudes concernant l'utilisation de l'intelligence artificielle générative. Ces questions portent non seulement sur la qualité des contenus créés, mais également sur les risques d'abus.

- **Abus et désinformation :** L'intelligence artificielle générative peut être utilisée de manière inappropriée pour produire des contenus réalistes, comme des deepfakes, des fausses nouvelles, des documents fictifs et d'autres formes de désinformation.
- **Droits d'auteur et propriété intellectuelle :** Le contenu créé pose des interrogations en matière de droits d'auteur et de propriété intellectuelle, car il est souvent complexe de déterminer qui possède les droits sur le contenu créé et comment il peut être exploité.
- **Éthique :** Les questions éthiques peuvent être soulevées par la création de faux contenus et d'informations manipulées.
- **Sécurité :** l'intelligence artificielle générative peut servir à des attaques d'ingénierie sociale plus efficaces que les attaques humaines.

III. Large Language Model :

1. Définition

Les grands modèles de langage (LLM) sont des systèmes avancés d'intelligence artificielle (IA) élaborés pour traiter, comprendre et créer du texte de nature humaine. Ils sont basés sur des techniques d'apprentissage en profondeur et formés sur des ensembles de données massifs, contenant en général des milliards de mots provenant de différentes sources telles que des sites web, des livres et des articles. Grâce à cette formation approfondie, les LLM ont la capacité de comprendre les subtilités de la langue, de la grammaire, du contexte et même de certaines notions générales.

2. L'essor de Large Language Model

Les LLM ont existé depuis de nombreuses décennies, mais ce n'est qu'à ce moment-là qu'ils sont devenus assez puissants et sophistiqués pour être utilisés à de multiples fins. Eliza, le premier chatbot, a été le déclencheur du premier LLM dans les années 1960. Cependant, ses capacités étaient extrêmement restreintes. Ce n'est qu'à partir des années 2010 qu'ils ont réussi à atteindre un niveau de fonctionnalité adapté aux très grands modèles et aux applications du monde réel. L'introduction de l'architecture Transformer en 2017 a marqué un tournant. Ce modèle a énormément aidé à comprendre les relations entre les mots dans les phrases. Le texte généré était à la fois convenable en termes de grammaire et cohérent en termes de sémantique.

Au fil des années, les LLM ont été préparés pour faire face à de vastes ensembles de données, des centaines de milliards de textes et de codes. Leurs performances ont été considérablement améliorées dans divers domaines. Par exemple, certains d'entre eux sont maintenant capables de produire du texte qui peut être difficile à différencier d'un texte écrit par un humain.




Figure 11 : Historique de LLM

3. Modèle de transformateur

Un modèle de transformateur constitue l'architecture la plus courante d'un LLM. Celle-ci est composée d'un encodeur et d'un décodeur. Les données sont converties en tokens par un modèle de transformateur, puis des équations mathématiques sont menées simultanément pour découvrir les relations qui existent entre les tokens. De cette façon, l'ordinateur peut repérer les schémas que l'homme pourrait déterminer s'il lui soumettait la même demande.

Les modèles de transformateur ont une meilleure capacité d'apprentissage que les modèles traditionnels, comme les modèles de longue mémoire à court terme (LSTM), en raison de mécanismes d'auto-attention. Un modèle de transformateur auto-attentif peut examiner différentes parties d'une séquence ou l'intégralité du contexte d'une phrase pour produire des prédictions.

4. Principaux composants de LLM

Les LLM sont constitués de plusieurs couches de réseaux de neurones. Pour traiter le texte d'entrée et produire le contenu de sortie, les couches récurrentes, les couches à action directe, les couches de plongement et les couches d'attention fonctionnent de façon synergique.

- La **couche de plongement** génère des plongements en se basant sur le texte d'entrée. Dans cette partie du LLM, on capture la signification sémantique et syntaxique de l'entrée pour que le modèle puisse appréhender le contexte.
- La **couche à action directe (FFN)** d'un LLM est composée de plusieurs couches entièrement connectées qui transforment les plongements d'entrée. En agissant de cette manière, ces couches permettent au modèle de recueillir des concepts généraux, c'est-à-dire de saisir l'intention de l'utilisateur avec le texte d'entrée.
- La **couche récurrente** interprète les mots du texte d'entrée dans l'ordre. Elle saisit la relation entre les mots dans une phrase.
- Le **mécanisme d'attention** permet à un LLM de se focaliser sur une partie spécifique du texte d'entrée appropriée pour la tâche en cours. Grâce à cette couche, le modèle peut produire les sorties les plus précises.

5. Les différents types de LLM

Il y a une variété évolutive de termes pour décrire les divers types de modèles de langage à grande échelle. Les types les plus courants sont les suivants :

- **Modèles zero-shot** : sont des modèles largement généralisés, développés à partir d'un corpus de données génériques, et qui peuvent fournir un résultat assez précis pour des situations d'utilisation générales. Il n'est pas indispensable d'effectuer un entraînement supplémentaire en IA.
- **Modèles spécifiques à un domaine** : peuvent être affinés grâce à une formation supplémentaire sur un modèle zero-shot, qui est spécifique à ce domaine.

- **Modèle de langage** : est une forme de LLM spécialement conçue pour comprendre et produire du langage humain. On utilise fréquemment ces modèles pour des opérations comme la traduction automatique, la création de texte, la synthèse de texte et la réponse aux questions.
- **Modèle multimodal** : les LLM ont été initialement conçus pour traiter du texte uniquement. Grâce à l'approche multimodale, il est possible de traiter à la fois du texte et des images.

6. Fonctionnement de LLM

Un LLM repose sur un modèle de transformateur. La méthode de fonctionnement est la suivante : il reçoit une entrée, l'encode, puis la décode afin de générer une prédiction de sortie. Mais avant qu'un LLM puisse recevoir une entrée de texte et produire une prédiction de sortie, il est nécessaire de le former afin qu'il puisse accomplir des fonctions générales et de l'adapter pour accomplir des tâches spécifiques.

- **Entraînement** : Les grands modèles de langage sont pré-entraînés en utilisant un large éventail de données textuelles provenant de sources telles que Wikipédia et GitHub. Il y a des milliards de mots dans ces ensembles, et leur qualité a un impact sur les performances des modèles. Lors de cet apprentissage non supervisé, les modèles manipulent les données sans instructions spécifiques, ce qui leur permet d'apprendre le sens des mots ainsi que les relations contextuelles. Ils apprennent aussi à distinguer les nuances de sens, comme déterminer si "gauche" est l'opposé de "droite" ou "maladroit".
- **Ajustement** : pour permettre à un LLM d'effectuer une tâche spécifique, par exemple une traduction, il doit être ajusté en fonction de cette activité. L'ajustement améliore les performances des tâches spécifiques.
- **Ajustement selon l'invite (prompt-tuning)** : il s'agit d'une fonction pareille à l'ajustement, lors de laquelle un modèle est entraîné pour réaliser une tâche spécifique à l'aide d'une invite de prompting en few-shot ou de prompting en zero-shot. Une invite est une consigne donnée à un LLM.

Le prompting en few-shot permet au modèle d'acquérir la capacité de prédire les sorties en lui fournissant quelques exemples. Par exemple, dans cette analyse des sentiments, une invite en few-shot se présenterait de la manière suivante :

Customer review : This plant is so beautiful ! Customer sentiment : positive
Customer review : This plant is so hideous ! Customer sentiment : negative

Le modèle de langage, en se basant sur le sens sémantique de "hideous" (hideux) et sur l'exemple donné en opposition, établira que le sentiment du client dans le second exemple est "négatif". En revanche, la méthode de prompting en zero-shot ne donne aucun exemple au modèle de langage afin de lui enseigner comment répondre aux entrées. Au lieu de cela, il pose la question en donnant une définition du sentiment qui s'applique au texte. Il précise de manière explicite la tâche à accomplir par le modèle de langage, mais ne propose pas d'exemples de résolution de problèmes.

7. Cas d'utilisation des LLM

Les LLM peuvent être utilisés pour divers objectifs :

- **Récupération d'informations** : pensez à Bing ou Google. Quand vous exploitez leur fonctionnalité de recherche, vous vous basez sur un vaste modèle de langage afin de générer des données en réponse à une demande. Il a la capacité de collecter des données, de les synthétiser et de communiquer la réponse de manière échangeant.
- **Analyse des sentiments** : les grands modèles de langage, en tant qu'outils de traitement du langage naturel, offrent aux entreprises la possibilité d'analyser le sentiment des données textuelles.
- **Génération de textes** : L'IA générative repose sur de grands modèles de langage, tels que ChatGPT, qui peuvent produire du texte en fonction des entrées. L'invitation leur permet de créer un exemple de texte. Par exemple : "Écris-moi un poème sur des palmiers dans le style d'Emily Dickinson".
- **Chatbots et IA conversationnelle** : grâce aux grands modèles de langage, les chatbots ou l'intelligence artificielle conversationnelle d'un service client ont la capacité d'interagir avec les clients, d'interpréter le sens de leurs questions ou de leurs réponses, et souvent de leur donner des réponses à leur tour.

8. Limites de LLM

Les grands modèles de langage (LLM) ont plusieurs limites malgré leur grande puissance. L'intégration des biais des données d'entraînement peut conduire à la reproduction de stéréotypes et de préjugés, ce qui comporte des risques, notamment légaux. En outre, les LLM peuvent avoir des hallucinations, générant des informations plausibles mais incorrectes, ce qui pose problème lorsque l'exactitude est primordiale.

Par ailleurs, les LLM sont restreints par une fenêtre contextuelle, ce qui restreint leur capacité à traiter plusieurs mots en même temps et complique l'utilisation de documents longs. Les coûts d'inférence sont élevés en raison des serveurs puissants requis, ce qui pose un obstacle aux petites entreprises ou aux projets avec des budgets limités.

IV. Retrieval-augmented generation :

1. Définition

L'approche architecturale appelée génération augmentée de récupération (RAG) permet d'améliorer l'efficacité des applications de grands modèles de langage (LLM) en utilisant des données sur mesure. Son objectif est de collecter des informations et des documents pertinents pour répondre à une question ou réaliser une tâche, puis de les fournir au LLM en tant que contexte de travail. Les chatbots d'assistance et les systèmes de Q&R de la RAG ont démontré leur efficacité en utilisant des informations à jour ou en accédant à des connaissances spécifiques à un domaine spécifique.

2. Comment fonctionne le Retrieval-augmented generation ?

Pour résumer, les RAG se composent de deux étapes principales.

- Une **étape de récupération (retrieval)** qui vise à extraire des données pertinentes de la base de connaissances, que ce soit dans une base de données ou dans des documents. Même si cette étape peut se concentrer sur des mots-clés, les méthodes modernes utilisent plutôt des techniques basées sur l'embedding que nous allons étudier en détail.

- Une **étape de génération** consiste à extraire les informations recherchées et à générer une réponse en langage naturel par un LLM. L'avantage d'utiliser un LLM ici réside dans le fait de ne pas donner directement à un utilisateur l'information extraite en brut, mais de l'enrichir avec un texte en langage naturel. À cette étape, il est possible d'utiliser différents LLM tels que GPT, LLaMa ou encore Mistral.




Figure 12 : Architecture d'un Système RAG pour Q/R

3. Loader et Splitter

Pour établir un RAG, il est essentiel de référencer et de regrouper tous les documents nécessaires pour servir de base de connaissances. Il est possible que ces documents soient de différentes natures : des fichiers textes ou Word, des présentations, des PDF, des pages Web ou même des transcriptions de vidéos YouTube. Certains frameworks tels que LangChain offrent de multiples intégrations afin de faciliter le chargement de divers types de documents sans nécessiter de développer de nouvelles fonctionnalités.

Après avoir chargé les documents, il est essentiel de les transformer de manière astucieuse, en particulier étant donné que l'on souhaite au moins découper un document de plusieurs pages en plusieurs blocs de texte. On effectue cette étape en utilisant un splitter, qui a pour fonction de séparer de manière efficace les documents en blocs de textes qui sont sémantiquement liés.

En premier lieu, le splitter débute en fragmentant le texte en petits morceaux, généralement de la taille d'une ou deux phrases. Il va ensuite fusionner ces blocs afin de créer des blocs plus grands sans dépasser une certaine

taille. Finalement, il va effectuer la même opération en utilisant l'overlapping, c'est-à-dire en faisant chevaucher une partie des blocs entre eux afin de maintenir un minimum de contexte entre deux blocs successifs. Par exemple, dans l'illustration ci-dessous, on peut observer divers blocs qui sont basés sur l'article Wikipédia du journal Le Monde.

	Text	Tokens	Characters
0	Le Monde est un journal français fondé par Hubert Beuve-Méry en 1944. Se voulant journal « de réfé	132	397
1	C'est le quotidien national payant le plus lu en France avec 2,44 millions de lecteurs en 202113 et le j	132	440
2	En 2010, sa ligne éditoriale est présentée comme étant de centre gauche15. En avril 2012, un sondag	96	338
3	Le journal Le Monde est détenu par le Groupe Le Monde. Il a pour actionnariat la holding Le Monde	96	336
4	La rédaction du Monde s'est située 5, rue des Italiens à Paris, de sa création jusqu'en 1989 (photo pri	38	115
5	Le premier numéro du Monde paraît le 18 décembre 1944, daté du 19 décembre sur une seule page r	149	506
6	titres ayant paru sous l'occupation de la France par l'Allemagne, a vu ses locaux réquisitionnés et so	147	510
7	l'équipe rédactionnelle, les ouvriers et employés ainsi que les anciens locaux situés rue des Italiens,	146	510
8	». Le général de Gaulle, qui souhaite doter la France d'un « journal de prestige » tourné vers l'étrange	136	507
9	charge son ministre de l'Information Pierre-Henri Teitgen d'en trouver le directeur, choix difficile car	140	506

Figure 13 : Analyse des Tokens et des Caractères des Textes du Journal Le Monde

4. Embedding

L'embedding est une technique d'encodage qui consiste à utiliser des vecteurs pour représenter des mots ou une partie d'un mot (comme une syllabe). Cette représentation permet de réaliser des calculs numériques sur des mots, tels que la recherche sémantique, en cherchant à construire des vecteurs dans un espace à grande dimension (200, 500 voire plus), car les vecteurs associés aux mots d'un même contexte seraient proches les uns des autres (au sens de la similarité cosinus par exemple). Le choix de l'embedding est très important, car c'est précisément sur ce dernier qu'un RAG se fonde pour déterminer le champ sémantique associé à une requête formulée par l'utilisateur : plus l'embedding est précis, plus le RAG sera en mesure de comprendre ce que l'utilisateur demande et sera plus en mesure de fournir une réponse pertinente.

5. Vector Store

Comme mentionné précédemment, les vecteurs jouent un rôle essentiel dans les LLM et les RAG, car ils offrent la possibilité de représenter les mots sous forme de vecteurs, en englobant un maximum d'informations en fonction des contextes dans lesquels ce mot a été identifié. Il est donc essentiel que nos algorithmes puissent accéder aux informations vectorielles de chaque mot de manière facile et rapide.




Figure 14 : Représentation vectorielle des relations sémantiques

Or, lors de l'enregistrement de ces vecteurs sur le disque dur, les délais de lecture et de décodage des données peuvent entraver la rapidité de réponse fournie. Afin de faciliter la lecture et l'écriture de vecteurs d'embedding, des bases de données vectorielles ont été développées, en particulier en stockant de manière intelligente les vecteurs lorsque ceux-ci sont similaires. Différentes bases de données vectorielles peuvent être exécutées localement, telles que Chroma ou FAISS, ainsi que des bases qui sont gérées dans le Cloud, telles que Pinecone ou Weaviate.




Figure 15 : Flux de Travail des Magasins de Vecteurs

6. Retrieval

L'étape de recherche d'informations dans la base de connaissances est la dernière étape du RAG, et elle est aussi l'une des plus importantes. L'intérêt principal des retrievers réside dans la recherche de la source d'une information demandée par un usager. Il est possible d'inclure une réponse précise (comme une date, un nom ou un identifiant), ainsi qu'un paragraphe si l'utilisateur souhaite un extrait ou si le contexte associé doit être fourni

dans la réponse.

À noter qu'en théorie, il n'est pas nécessaire que le retrieval utilise une base de données vectorielle pour rechercher la source d'une information, mais la majorité des retrievers le font néanmoins. Il y a déjà des frameworks qui offrent une gamme complète de composants permettant de créer ses propres RAG. Il en va de même pour LangChain, où toutes les étapes de construction d'un RAG sont accessibles, depuis le chargement de données jusqu'à la récupération, et même avec des fonctionnalités supplémentaires telles que l'indexation.

7. Avantages et risques d'utilisation d'un Retrieval-augmented generation

Les entreprises peuvent bénéficier de nombreux avantages en utilisant un RAG (Retrieval-Augmented Generation), notamment en rendant la documentation interne rapidement et facilement accessible, cela aide à améliorer la pertinence des réponses par rapport à un LLM sans RAG. Cette documentation peut inclure des documents de fonctionnement interne et des outils pour gagner en efficacité. Grâce au RAG, il est possible de mettre à jour les informations provenant de diverses sources sans avoir à suivre un nouvel entraînement, ce qui permet d'accélérer la mise à disposition des informations mises à jour.

Néanmoins, il existe des risques, en particulier pour des sujets critiques tels que la médecine ou le droit. Il est conseillé de vérifier la source des informations fournies pour s'assurer que les réponses générées par un LLM avec RAG sont toujours exactes. De plus, il est essentiel de s'assurer que la base de connaissances ne contient pas d'informations sensibles qui peuvent être consultées sans autorisation appropriée, afin d'empêcher les utilisateurs d'accéder à des données qu'ils ne devraient pas voir.

8. Fine-Tuning :

8.1 Définition

Le fine-tuning de LLM implique d'ajuster les paramètres du modèle pour qu'il soit adapté à une tâche spécifique ou à un domaine spécifique. La plupart des LLM modernes, tels que ChatGPT, Mistral ou Llama, sont conçus pour être le plus générique possible. Néanmoins, ils ne possèdent pas une certaine spécialisation sur des sujets spécifiques.

V. Conclusion :

Dans ce chapitre, nous avons abordé les concepts techniques clés tel que : LLM, soulignant leur pertinence dans notre contexte de notre projet. Ces concepts jetteront les fondements essentiels pour le développement de notre Chatbot conversationnelle avec les documents PDF. D'après avoir effectué des recherches approfondies, nous avons mis en place une base de connaissances essentielle qui sera essentielle pour le développement de notre chatbot conversationnel utilisant les fichiers PDF. Grâce à ces idées, nous pourrons élaborer une solution novatrice et efficace, qui répondra aux besoins spécifiques de notre projet.

Chapitre III : Analyse et Conception du projet

I. Introduction :

Dans ce chapitre, nous allons détailler l'analyse des besoins ainsi que la conception du chatbot basé sur le modèle de génération augmentée par récupération (RAG) que nous avons développé en utilisant LangChain et ChromaDB. L'analyse des besoins permet de clarifier les fonctionnalités essentielles du système ainsi que les contraintes techniques qui ont guidé nos choix de conception. Ensuite, à travers une série de diagrammes UML, nous illustrerons la structure du système, y compris les interactions entre les différents composants et la dynamique des processus internes. Cette étape est cruciale pour s'assurer que le système répondra de manière optimale aux objectifs du projet. Enfin, nous discuterons des principaux composants du projet et leur rôle dans la réalisation de notre solution.

II. Analyse :

1. Identification des acteurs :

Tout système interactif doit assurer et faciliter l'interaction avec ses utilisateurs, qu'ils soient humains ou non humains. Un acteur représente le rôle d'une entité externe exploitant le système à travers ses différentes interfaces. Les acteurs du système se divisent en plusieurs catégories : L'Administrateur Système assure la sécurité, la conformité et la performance du système. Le Chef de Projet / Manager est responsable de la planification, du suivi, de la gestion des ressources, de la communication, de la prise de décision et de la génération de rapports d'avancement. Il supervise également les initiatives de transport, optimise les décisions et répartit les tâches. Le Membre de Projet exécute les tâches opérationnelles, collabore avec l'équipe, suit les instructions, fournit des mises à jour régulières et participe à des formations continues. Les Analystes de Données identifient les inefficacités et recommandent des solutions d'amélioration. L'Utilisateur Final (Client) définit les besoins, valide les livrables, fournit des retours, participe aux réunions, approuve le produit final et évalue la satisfaction globale. Il accède également aux informations et suit les livraisons.

2. Identification des besoins :

2.1 Besoins fonctionnels :

❖ Authentification :

Pour garantir la sécurité des utilisateurs et la personnalisation de l'expérience, une fonctionnalité d'authentification est nécessaire. Cela permettra aux utilisateurs de créer un compte, de se connecter de manière sécurisée, et d'accéder à leurs données personnelles. Cette fonctionnalité inclura également des mécanismes pour la récupération de mot de passe en cas d'oubli.

❖ Gestion des documents (PDF) :

Le système doit permettre aux utilisateurs de télécharger des documents PDF entiers, qui seront ensuite stockés de manière sécurisée. Une fonctionnalité supplémentaire permet aux utilisateurs de sélectionner des portions spécifiques de texte à partir de ces PDF, en s'appuyant sur l'historique des conversations. Cela donne la possibilité au chatbot de se concentrer sur les segments pertinents du document, rendant les réponses plus précises et adaptées au contexte.

❖ Historique des conversations :

Pour améliorer l'expérience utilisateur et permettre une continuité dans les interactions, le système doit conserver l'historique des conversations. Cette fonctionnalité permettra aux utilisateurs de revenir sur les discussions précédentes et au chatbot d'utiliser ce contexte pour affiner ses réponses lors des interactions futures.

❖ Mémoire du chatbot :

Une des fonctionnalités clés du chatbot est sa capacité à mémoriser le contexte des conversations passées. Cela lui permet de fournir des réponses plus précises et cohérentes, en tenant compte des échanges précédents avec l'utilisateur. La gestion de cette mémoire inclut à la fois une mémoire à court terme, pour les sessions en cours, et potentiellement une mémoire à long terme, pour les utilisateurs récurrents.

2.2 Besoins non fonctionnels :

Les besoins non fonctionnels, également appelés exigences non fonctionnelles, sont des critères qui décrivent comment un système doit se comporter et quelles contraintes il doit respecter pour être efficace, sûr, fiable, et utilisable. Voici une définition des besoins non fonctionnels pour le projet de chatbot RAG :

- | | |
|---------------------------------------|---------------------------|
| ❖ Sécurité : | ❖ Performance : |
| ❖ Fiabilité et disponibilité : | ❖ Accessibilité : |
| ❖ Scalabilité : | ❖ Maintenabilité : |

Ces besoins non fonctionnels sont essentiels pour garantir que ton projet de chatbot RAG soit non seulement fonctionnel, mais aussi sécurisé, fiable, performant, accessible et maintenable à long terme. Ils définissent les standards de qualité que le système doit respecter pour répondre aux attentes des utilisateurs et des parties prenantes.

III. Diagrammes

1. Diagramme Cas d'utilisation :

Les principaux cas d'utilisation pour l'utilisateur utilisant cette application d'IA incluent la gestion et l'analyse de documents au format PDF. Une fois connecté à l'application, l'utilisateur peut télécharger un fichier PDF qu'il souhaite examiner.

L'IA de l'application prend alors en charge la lecture et l'analyse du contenu pour en extraire des informations pertinentes, telles que les parties impliquées, les dates importantes, et les clauses spécifiques. À travers une interface interactive, l'IA initie une conversation avec l'utilisateur pour préciser les informations recherchées et guide l'utilisateur dans l'extraction des données requises.

Lorsqu'il y a des ambiguïtés ou des erreurs, l'IA demande des éclaircissements pour assurer l'exactitude de l'information. Après cette interaction, les données extraites sont présentées de manière structurée, ce qui facilite leur compréhension et leur utilisation ultérieure par l'utilisateur. Une fois que l'analyse est terminée ou que le l'utilisateur a pris la décision de conclure, l'IA remercie l'utilisateur et se met en veille, prête pour la prochaine session.




Figure 16 : Diagramme de cas d'utilisation d'utilisateur

2. Diagramme de Séquence

Un diagramme de séquence montre simplement l'ordre dans lequel les éléments interagissent, ou l'ordre dans lequel ces interactions se produisent. Les diagrammes de séquence montrent comment et dans quel ordre les composants d'un système travaillent ensemble. Les ingénieurs logiciels utilisent fréquemment ces diagrammes pour décrire et comprendre les besoins des systèmes nouveaux et actuels.

Voici pour ce projet, le diagramme de séquence du système de chatbot utilisant la technologie Retrieval Augmented Generation (RAG) :




Figure 17 : Diagramme de séquence du système RAG du chatbot

2.1 Composants principaux du chatbot :

1. Cadre général pour les applications utilisant un LLM :

- **Rôle** : Ce composant sert de structure de base pour le développement de ton application, facilitant l'intégration et la gestion des interactions avec un grand modèle de langage (LLM). Il fournit les outils et les interfaces nécessaires pour orchestrer les différentes étapes du traitement du langage naturel, de l'interaction utilisateur à la génération de réponses.
- **Fonctionnalités** : Le cadre gère les flux de travail impliquant le LLM, les appels aux modèles d'embeddings et d'OCR, et la gestion des données. Il simplifie la création de chaînes de traitement personnalisées adaptées aux besoins spécifiques de l'application.

2. Grand Modèle de Langage (LLM) :

- **Rôle** : Le LLM est au cœur du système, responsable de la compréhension des requêtes des utilisateurs et de la génération des réponses. Il est entraîné sur de vastes quantités de données textuelles pour comprendre le contexte et produire du texte cohérent et pertinent.
- **Fonctionnalités** : Le LLM traite les entrées utilisateur, interagit avec les données disponibles (par exemple, des documents PDF), et produit des réponses textuelles qui répondent aux questions posées ou aux tâches demandées.

3. Modèle d'Embeddings :

- **Rôle** : Ce modèle transforme les données textuelles en représentations numériques (embeddings) qui capturent les significations sémantiques du texte. Ces embeddings sont ensuite utilisés pour des tâches comme la recherche d'information ou la comparaison de similarités entre différents textes.
- **Fonctionnalités** : Le modèle d'embeddings est utilisé pour indexer et rechercher des informations pertinentes dans les documents en se basant sur leur contenu sémantique. Cela permet au système de retrouver rapidement les données les plus pertinentes pour répondre aux requêtes des utilisateurs.

4. Modèle d'OCR (Reconnaissance Optique de Caractères) :

- **Rôle** : Le modèle d'OCR est chargé de convertir les textes présents dans des images ou des PDF en texte exploitable par le système. Cela permet de traiter des documents scannés ou des images contenant du texte, les rendant accessibles pour l'analyse et la recherche.
- **Fonctionnalités** : Le modèle d'OCR extrait le texte de supports visuels, le convertissant en un format numérique utilisable. Cela permet d'inclure des documents non textuels dans le flux de travail du LLM et des modèles d'embeddings.

5. Base de Données Vectorielles :

- **Rôle** : Cette base de données est utilisée pour stocker et gérer les embeddings générés par le modèle d'embeddings. Elle permet des recherches rapides et efficaces, basées sur des requêtes vectorielles, qui sont essentielles pour retrouver les informations pertinentes parmi de grands ensembles de données.
- **Fonctionnalités** : La base de données vectorielles permet l'indexation et la recherche des embeddings, facilitant ainsi les opérations comme la recherche sémantique, la classification, ou le regroupement d'informations similaires.

3. Diagramme de composants

Le diagramme de composants en haut montre l'architecture logicielle d'une application chatbot, mettant en évidence l'interaction entre l'utilisateur et les divers composants du système. Cet utilisateur a la possibilité d'accéder à l'interface web FrontEnd. Cette interface permet le chargement de documents PDF et la communication avec un chatbot IA pour une assistance en temps réel. Au cœur du système, le Backend API orchestre la communication entre le FrontEnd et les services internes, y compris le traitement des fichiers PDF.




Figure 18 : Diagramme de composant

IV. Conclusion :

Cette section a permis de détailler les aspects essentiels de l'analyse et de la conception du projet de chatbot RAG (Retrieval-Augmented Generation) utilisant un cadre général pour les applications basées sur un grand modèle de langage (LLM).

Dans l'analyse des besoins fonctionnels, nous avons identifié les fonctionnalités clés que le système doit offrir, telles que l'authentification des utilisateurs, la gestion des documents PDF (incluant la possibilité de sélectionner du texte à partir des documents), la gestion de l'historique des conversations, et la capacité du chatbot à conserver le contexte des échanges passés grâce à une mémoire adaptée. Les besoins non fonctionnels ont également été précisés, soulignant l'importance de la sécurité des données, de la fiabilité du système, de sa scalabilité, de ses performances, et de son accessibilité.

La conception du système a été illustrée à travers des diagrammes UML, montrant les interactions entre les acteurs principaux et le système, ainsi que la structure interne du projet. Les différents composants du projet, tels que le LLM, le modèle d'embeddings, le modèle d'OCR, et la base de données vectorielles, ont été décrits en détail, mettant en évidence leurs rôles respectifs et leurs interactions.

En conclusion, cette analyse et conception forment une base solide pour la réalisation du projet, assurant que le système répondra aux besoins identifiés tout en étant conçu pour évoluer et maintenir des performances optimales dans divers scénarios d'utilisation.

Chapitre IV : Langages et outils utilisés

I. Introduction :

Dans le cadre de notre étude comparative, nous avons évalué LangChain et Llama Index pour déterminer leur performance et adéquation à nos besoins spécifiques. Nous avons effectué plusieurs types de tests, cela inclut le temps de réponse moyen pour diverses requêtes, et la simulation d'un grand nombre d'utilisateurs simultanés pour évaluer la gestion des charges élevées sans perturber les performances. Après ces tests et analyses, nous avons opté pour LangChain pour diverses raisons :

II. Benchmarking :

1. Choix du Framework :

Dans le cadre de notre étude comparative, nous avons évalué LangChain et Llama Index pour déterminer leur performance et adéquation à nos besoins spécifiques. Nous avons effectué plusieurs types de tests, cela inclut le temps de réponse moyen pour diverses requêtes, et la simulation d'un grand nombre d'utilisateurs simultanés pour évaluer la gestion des charges élevées sans perturber les performances. Après ces tests et analyses, nous avons opté pour LangChain pour diverses raisons :

- **Richesse fonctionnelle** : LangChain offre une architecture modulaire et extensible, permettant une intégration facile avec diverses sources de données et services.
- **Facilité d'utilisation** : Il fournit une cohérence contextuelle dans les conversations, rendant les interactions plus pertinentes et cohérentes.
- **Flexibilité et évolutivité** : LangChain permet une personnalisation poussée, ce qui nous aide à répondre précisément à nos besoins.
- **Support communautaire et documentation** : Avec une communauté active et une documentation étendue, LangChain facilite l'apprentissage et la résolution de problèmes.
- **Rentabilité** : LangChain offre un bon rapport qualité-prix avec ses options de personnalisation et d'extension, contrôlant ainsi les coûts de déploiement.

2. Justification du choix du Retrieval augmented generation :

D'après plusieurs recherches approfondies comparant entre le Finetuning et le RAG. Le RAG est idéal pour notre projet car elle intègre des informations précises et à jour provenant de sources de connaissances externes, ce qui permet des réponses contextuelles précises. Ce modèle se démarque des approches de finetuning et d'ingénierie des prompts en combinant leurs avantages sans en subir les inconvénients. Le finetuning peut être restrictif voire inapproprié, tandis que l'ingénierie des prompts peut manquer de

précision. RAG, en revanche, assure la flexibilité et l'exactitude en temps réel, faisant de lui un choix privilégié pour des chatbots qui nécessitent des réponses détaillées et spécifiques sur une large gamme de sujets. Cela favorise une interaction plus riche et plus informée, ce qui est crucial dans les environnements dynamiques où les chatbots doivent répondre avec précision et précision.

3. Choix du Large Model Language

Lors de notre évaluation des modèles de langage à grande échelle (LLM) pour le benchmarking, l'option d'un LLM open source a été privilégiée principalement pour ses avantages en termes de coût et de flexibilité. Les modèles open source, tels que : LLaMA 2, GPT-4, etc. Ils offrent une transparence complète, permettant une personnalisation et une adaptation approfondies selon les besoins spécifiques des utilisateurs. Ils facilitent également la collaboration et l'innovation au sein de la communauté de développeurs, ce qui est essentiel pour l'évolution rapide des technologies d'intégration de données et de traitement du langage naturel.

Quant à GPT-3.5 Turbo, sélectionné pour notre projet, il se distingue par ses statistiques impressionnantes en termes de performance et de coût. Selon les analyses d'Artificial Analysis, GPT-3.5 Turbo offre un excellent rapport qualité-prix, avec une vitesse de traitement élevée (tokens par seconde) et un coût compétitif par token. Ces caractéristiques le rendent particulièrement adapté pour les applications nécessitant à la fois une haute performance et une gestion économique des ressources, rendant ainsi notre choix judicieux pour répondre efficacement à nos exigences de traitement linguistique en temps réel. Ces aspects soulignent l'importance de choisir des modèles adaptés aux besoins spécifiques tout en considérant les avantages financiers et techniques offerts par les options open source et les modèles comme GPT-3.5 Turbo.

4. Choix du Base de données vectorielles

Dans notre évaluation des bases de données vectorielles, nous avons opté pour ChromaDB, une solution open source, principalement en raison de ses capacités notables dans la gestion des embeddings pour l'intelligence artificielle. ChromaDB se distingue par sa facilité d'utilisation, sa scalabilité, et son intégration robuste avec des applications de machine learning. Cela inclut le support de diverses fonctionnalités d'apprentissage automatique et l'intégration avec des environnements d'IA dynamiques pour des réponses rapides, ce qui est crucial pour les applications comme la recherche sémantique et le traitement du langage naturel. Ces caractéristiques rendent ChromaDB particulièrement adapté pour gérer efficacement des ensembles de données complexes et volumineux, tout en restant flexible et évolutif selon les besoins des utilisateurs.

5. Choix du Model d'ocr

Tesseract OCR (Optical Character Recognition) est un moteur open-source développé par Google, permettant la reconnaissance optique de caractères dans des images et des documents scannés. Il convertit les informations visuelles en texte éditable et exploitable. Tesseract prend en charge une multitude de langues et offre la possibilité d'entraîner de nouveaux modèles linguistiques. Grâce à ses capacités robustes de reconnaissance et à sa flexibilité, Tesseract OCR est couramment utilisé pour extraire du texte à partir de formats non éditables tels que les images, les PDF, et d'autres sources visuelles, facilitant ainsi l'automatisation des tâches de transcription et l'intégration des données textuelles dans des systèmes numériques..

6. Choix du Model d'embedding

Dans le cadre du développement de mon chatbot RAG (Retrieval-Augmented Generation), j'ai choisi d'utiliser le modèle d'embedding Voyage-Law pour plusieurs raisons stratégiques. Ce modèle est conçu pour transformer des textes en représentations vectorielles de haute qualité, adaptées aux applications de traitement du langage naturel (NLP) dans des contextes où la précision et la pertinence sont cruciales.

1. **Performance en Langue Française** : Le modèle Voyage-Law est particulièrement performant pour le traitement des textes en langue française. Grâce à son entraînement sur des données diversifiées et de haute qualité, il est capable de capturer les nuances linguistiques spécifiques au français, ce qui en fait un choix optimal pour des applications nécessitant une compréhension fine et contextuelle des textes dans cette langue.
2. **Qualité des Embeddings** : Voyage-Law produit des embeddings vectoriels qui capturent non seulement la sémantique des mots individuels, mais aussi les relations contextuelles entre les phrases et les paragraphes. Cela permet d'améliorer les performances du système lors de la recherche de passages pertinents dans de grandes bases de données textuelles, comme les collections de documents PDF intégrées dans ChromaDB.
3. **Compatibilité avec RAG** : Le modèle Voyage-Law s'intègre bien dans une architecture RAG, où la capacité à récupérer des informations précises et pertinentes est essentielle pour améliorer la qualité des réponses générées par le chatbot. En utilisant un modèle d'embedding performant en français, le système bénéficie d'une meilleure contextualisation des requêtes, ce qui se traduit par des réponses plus pertinentes et précises.

4. **Optimisation pour l'OCR** : En complément de l'utilisation de Tesseract OCR pour extraire le texte des documents, Voyage-Law permet de traiter ces textes de manière efficace et de les convertir en représentations vectorielles prêtes à être indexées et recherchées. Cela est particulièrement utile dans les cas où les documents contiennent un langage dense et complexe en français.

1. Outils, langage, Technologies et Architecture logicielle :

1.1 Conception :



Enterprise Architect est un logiciel de modélisation et de conception UML développé par Sparx Systems, une entreprise australienne. Grâce à ses fonctionnalités, il couvre toutes les étapes du cycle de conception d'application, ce qui en fait l'un des logiciels de conception et de modélisation les plus reconnus. Il implique la documentation de haute qualité et la flexibilité. Le manuel d'utilisateur.

1.2 Technologies :



LangChain

LangChain est un Framework open source qui permet de développer des applications en utilisant de grands modèles de langage (LLM). LangChain offre des outils et des API pour simplifier la création d'applications alimentées par les LLM, tels que les chatbots et les agents conversationnels, qui sont disponibles dans les bibliothèques Python et Java.



L'API OpenAI, un outil crucial dans le développement actuel de l'IA, a joué un rôle crucial dans l'amélioration des capacités du chatbot. En utilisant des modèles de langage avancés comme le GPT-4 de cette API, les réponses créées sont beaucoup plus naturelles et fluides. Par conséquent, le chatbot ne se limite pas à fournir des informations de base, mais il fournit des réponses détaillées et réfléchies.

Notre utilisation de l'API a été très significative, en tirant pleinement parti de sa compréhension avancée du langage. Lorsque les utilisateurs envoyaient leur question au chatbot, l'API l'analysait attentivement et utilisait ces informations

pour créer une réponse personnalisée. De plus, la capacité de l'API permet au chatbot de comprendre et de communiquer dans plusieurs langues, ce qui lui permet de s'adapter à diverses entrées disponibles, les faisant ainsi se sentir accueillis et compris.

Flask est un framework web léger et flexible pour construire des applications web et des interfaces de programmation d'applications (APIs) en utilisant Python. Créé en 2010 par Armin Ronacher, Flask est open source et particulièrement apprécié pour sa simplicité et sa modularité, ce qui permet aux développeurs de choisir les composants qu'ils souhaitent intégrer.

Nous avons choisi Flask pour les raisons suivantes :



Flask

- **Documentation complète et soutien communautaire robuste** : Flask offre une documentation claire et détaillée, ainsi qu'un excellent support de la communauté.
- **Support des nombreux formats standards** : Bien que Flask soit minimaliste par défaut, il peut être facilement étendu pour supporter des formats comme JSON, XML, et bien d'autres à travers des extensions.
- **Création rapide et flexibilité** : Flask permet de créer rapidement une API REST tout en offrant la flexibilité nécessaire pour personnaliser et adapter l'application selon les besoins spécifiques du projet.



Chroma

ChromaDB est une base de données open-source d'embedding qui se distingue par sa facilité d'utilisation et ses nombreuses fonctionnalités. Elle permet une intégration simple avec des outils comme LangChain, LlamaIndex et OpenAI, tout en étant compatible avec les clients Python et JavaScript.

React est une bibliothèque JavaScript conçue pour construire des interfaces utilisateur. Développée initialement par Facebook, React permet de créer des composants réutilisables et dynamiques pour représenter les éléments de l'interface d'une application web. Grâce à sa gestion efficace du DOM virtuel (Virtual DOM), React optimise les mises à jour et rend le processus de développement plus performant. Cette bibliothèque permet de structurer les

interfaces de manière modulaire et de gérer les états internes des composants, facilitant ainsi la création d'applications interactives et réactives. De plus, React peut être utilisé pour intégrer des API externes, gérer des formulaires, et inclure des éléments multimédias, entre autres fonctionnalités.



Cascading Style Sheets (les feuilles de style en cascade), le CSS constitue un langage informatique permettant d'ajouter des contraintes de mise en forme graphique dans des documents web, dont les normes sont établies par le World Wide Web Consortium (W3C).



MySQL est un système de gestion de bases de données relationnelles (SGBDR). Il est distribué sous une double licence GPL et propriétaire. Il fait partie des logiciels de gestion de base de données les plus utilisés au monde, autant par le grand public (applications web principalement) que par des professionnels, en concurrence avec Oracle, Informix et Microsoft SQL Server.



XAMPP est un ensemble de logiciels permettant de mettre en place facilement un serveur Web confidentiel, un serveur FTP et un serveur de messagerie électronique. Il s'agit d'une distribution de logiciels libres (X (cross) Apache Maria DB Perl PHP) offrant une bonne souplesse d'utilisation, réputée pour son installation simple et rapide.

1.3 Sécurité :



JWT est une Norme « RFC 7519 » qui définit une approche sécurisée pour échanger des informations, sous la forme d'un objet structuré au format JSON (Java Script Object Notation), stocké depuis le côté du client et qui peut être intégré dans plusieurs langages. La plupart du temps, JWT est employé afin de concevoir des mécanismes d'authentification sans état pour des applications SPA (Single Page Application) ou pour des applications mobiles.

1.4 IDE De développement :



JWT est une Norme « RFC 7519 » qui définit une approche sécurisée pour échanger des informations, sous la forme d'un objet structuré au format JSON (Java Script Object Notation), stocké depuis le côté du client et qui peut être intégré dans plusieurs langages. La plupart du temps, JWT est employé afin de concevoir des mécanismes d'authentification sans état pour des applications SPA (Single Page Application) ou pour des applications mobiles.

1.5 Langage de Programmation :



C'est un langage de programmation qui s'accompagne d'un certain nombre de bibliothèques d'apprentissage automatique très attrayantes ainsi qu'un ensemble de paquets puissants pour les besoins analytiques. Cela m'a encouragé à choisir Python plutôt que d'autres langages de programmation. En outre, Python dispose d'une grande communauté qui fournit un soutien par le biais de forums, etc.



Tkinter est une bibliothèque standard de Python utilisée pour créer des interfaces graphiques utilisateur (GUI). Elle fournit un ensemble de widgets tels que des boutons, des étiquettes, des champs de texte, des menus et bien d'autres, permettant de concevoir et de développer facilement des applications de bureau interactives. Tkinter sert de liaison entre Python et la boîte à outils graphique Tcl/Tk, offrant ainsi une intégration native et une portabilité sur diverses plateformes comme Windows, macOS et Linux.

1.6 Débogage :



LangSmith est une technologie complémentaire à LangChain pour faciliter l'observabilité, l'inspectabilité, les tests et l'amélioration continue. LangSmith est particulièrement utile lors de l'exécution d'agents autonomes, où les différentes étapes ou chaînes de la séquence d'agent sont affichées. Également lorsque plusieurs requêtes parallèles sont envoyées aux LLM.

2. Architecture logicielle :

Une architecture logicielle exprime un schéma d'organisation structurel fondamental pour les systèmes logiciels. Elle s'avère indispensable pour la bonne compréhension, la gestion et l'optimisation de tout système. Pour une bonne structure, nous avons opté pour l'architecture RAG, adaptée à la gestion des documents. La figure ci-dessous représente l'architecture logicielle du chatbot RAG, dédiée à la manipulation et au traitement automatisé des documents.




Figure 19 : Architecture de déploiement

Dans notre architecture de déploiement, nous avons identifié trois nœuds essentiels :

1. Ordinateur avec navigateur web : Ce nœud représente l'interface utilisateur où les utilisateurs interagissent avec le chatbot via un navigateur web. Cela donne aux utilisateurs la possibilité de poser des questions et d'obtenir des réponses du chatbot directement sur leur ordinateur.
2. Serveur d'application : Ce nœud est crucial car il héberge le backend du système, y compris le traitement des fichiers PDF et l'authentification des utilisateurs. Il joue le rôle d'un lien entre l'interface utilisateur et les bases de données, en traitant les requêtes HTTP reçues du navigateur web et en renvoyant les réponses requises.
3. Serveurs de base de données : Deux bases de données sont utilisées.

❖ ChromaDB sert à stocker et gérer des données vectorielles ou autres données

structurées requises par le chatbot pour son bon fonctionnement.

- ❖ MySQL est un serveur de base de données relationnelle qui permet de gérer les informations d'authentification des utilisateurs et autorisations.

Ce déploiement garantit une interaction fluide et sécurisée pour les utilisateurs, ce qui permet au chatbot de fournir des réponses précises en se basant sur les informations des fichiers PDF.

3. Architecture applicative :

L'architecture applicative se concentre sur la structure logicielle de l'application, en organisant les différentes parties de manière à répondre aux besoins fonctionnels. Elle divise l'application en couches distinctes, à savoir la couche de présentation, la couche métier et la couche de données. Chaque couche a des responsabilités spécifiques et se préoccupe de préoccupations particulières. La couche de présentation assure la gestion de l'interface utilisateur, la couche métier assure la logique fonctionnelle et la couche de données assure la conservation et l'accès aux informations nécessaires. La séparation claire des responsabilités et la maintenabilité et la scalabilité de l'application sont favorisées par cette approche en couches.




Figure 20 : Architecture applicative

- ❖ **Couche de données :** Dans la couche de données, nous avons mis en œuvre plusieurs étapes pour traiter les documents et les rendre facilement accessibles et compréhensibles pour le chatbot. Je vais vous expliquer en détail les différentes étapes :

- Conversion des documents PDF en vecteurs :

Initialement, les documents disponibles étaient uniquement en PDF. Afin de les rendre utilisables par notre système de chatbot, nous avons d'abord extrait le contenu textuel de ces documents en utilisant des méthodes de traitement de texte.

Chaque fichier PDF a subi une conversion en un texte brut. Cette transformation est cruciale car elle prépare le texte pour le traitement et l'analyse ultérieurs. Par la suite, pour améliorer notre approche de

récupération et de génération de réponses, ce texte brut a été converti en vecteurs numériques. Grâce à cette vectorisation, il est plus facile de manipuler et d'analyser le contenu par notre système, en préparant les données pour les étapes suivantes du processus.

- **Stockage persistant des vecteurs :**

Il est essentiel de stocker les textes convertis en vecteurs pour assurer une récupération rapide et efficace pour les requêtes futures. Donc, nous avons opté pour les stocker dans un système optimisé pour la recherche vectorielle. Grâce à ce choix de stockage, il est possible de récupérer efficacement les données sans avoir à recourir à la retraite des documents à chaque nouvelle requête.

Cette méthode de stockage a un impact significatif sur les performances du chatbot en réduisant le temps de réponse et en améliorant la précision des interactions avec les utilisateurs. Grâce à cette infrastructure, notre chatbot peut rapidement fournir des réponses pertinentes, en se basant sur les informations extraites d'un vaste ensemble de documents textuels.

- ❖ **Couche métier :** Nous mettons en place les fonctionnalités essentielles du chatbot dans la couche métier afin de traiter les requêtes des utilisateurs. Cela implique d'utiliser des bibliothèques et des outils comme LangChain, OpenAI et Chroma. Ces éléments nous offrent la possibilité de concevoir un chatbot, de rechercher des documents pertinents et de produire des réponses en fonction de l'historique de la conversation utilisateur.
- ❖ **Couche de présentation :** Nous mettons en place l'interface utilisateur du chatbot dans la couche de présentation, afin que les utilisateurs puissent interagir. Grâce à cette interface, les utilisateurs peuvent soumettre leurs demandes et recevoir les réponses du chatbot. Pour rendre l'interaction avec le chatbot plus conviviale.

L'interface utilisateur intègre divers éléments, tels que :

- **L'interface d'authentification :**

Elle permet aux utilisateurs de se connecter de manière sécurisée pour accéder aux fonctionnalités du chatbot.

- **L'interface de messagerie :**

Elle fournit une zone de chat où les utilisateurs peuvent saisir leurs requêtes et afficher les réponses générées par le chatbot. Elle comprend aussi :

- **Recherche rapide dans l'historique :** Une barre de recherche pour repérer

facilement des conversations antérieures basées sur des mots-clés ou des dates

Pour créer une interface conviviale et interactive, nous utilisons des technologies modernes comme JavaScript, HTML et CSS pour développer l'interface utilisateur de notre chatbot. Dans le cadre de mon projet de fin d'études, il est primordial de souligner que je n'ai pas été directement impliqué dans le développement frontend. Une équipe dédiée est chargée de cette tâche en utilisant le framework React, afin de satisfaire aux exigences spécifiques de visualisation et d'interaction.

Cependant, dans ce projet, j'ai étudié la création d'une interface utilisateur en me basant sur ces technologies afin de repérer des axes d'amélioration et de suggérer des idées pour améliorer l'interactivité et l'expérience utilisateur du chatbot.

De plus, cette approche me permet d'avoir une meilleure compréhension des attentes et des défis associés à la création d'une interface utilisateur performante, ce qui peut être avantageux pour des futures collaborations avec l'équipe frontend.

Et pour bien comprendre la procédure de fonctionnement de notre application, voilà une illustration de cette procédure:




Figure 21 : Illustration de la procédure

III. Conclusion :

Dans le cadre de notre étude comparative, nous avons évalué LangChain et Llama Index pour déterminer leur performance et adéquation à nos besoins spécifiques. Nous avons effectué plusieurs types de tests, cela inclut le temps de réponse moyen pour diverses requêtes, et la simulation d'un grand nombre


d'utilisateurs simultanés pour évaluer la gestion des charges élevées sans perturber les performances. Après ces tests et analyses, nous avons opté pour LangChain pour diverses raisons :

Chapitre V : Réalisation

I. Introduction

Cette section décrit les étapes de développement de l'application, de la mise en place du backend à l'intégration de l'interface utilisateur et des technologies d'intelligence artificielle. Chaque composant a été soigneusement implémenté et testé avant d'être intégré dans le système global. Les défis techniques rencontrés ont été surmontés grâce à des solutions adaptées, garantissant la performance et la fiabilité de l'application. Cette réalisation concrétise les concepts théoriques abordés dans les phases précédentes, démontrant la faisabilité et l'efficacité de la solution développée.

II. Backend

A screenshot of a dark-themed code editor showing a list of API endpoints. The endpoints are listed line by line, with some using angle brackets for placeholders like <username> and <filename>. The endpoints are: /auth/register, /auth/login, /file/upload, /file/upload/text, /file/files, /file/file/download/<username>/<filename>, /query/query, /chat/create_chat, /chat/get_chats, /chat/<int:chat_id>/messages, and /chat/add_message.

```
/auth/register
/auth/login
/file/upload
/file/upload/text
/file/files
/file/file/download/<username>/<filename>
/query/query
/chat/create_chat
/chat/get_chats
/chat/<int:chat_id>/messages
/chat/add_message
```

Figure 22 : Backend API Endpoints

Cet écran présente un aperçu des différentes routes (endpoints) définies dans l'API backend de l'application. Ces routes sont essentielles pour la gestion des différentes fonctionnalités du système, telles que l'authentification des utilisateurs, la gestion des fichiers, et l'interaction avec le chatbot.

Les routes d'authentification (/auth) permettent aux utilisateurs de s'inscrire et de se connecter au système. Elles sont cruciales pour sécuriser l'accès aux données personnelles des utilisateurs et gérer les sessions de manière efficace. Les routes de gestion des fichiers (/file) offrent des fonctionnalités comme le téléchargement, l'affichage, et la récupération des fichiers. Cela inclut la possibilité de télécharger des textes spécifiques à partir des PDF stockés dans le système.

Enfin, les routes de gestion des chats (/chat) permettent de créer des sessions de chat, de récupérer des historiques de conversation, et d'ajouter de nouveaux messages à une session en cours. Chaque route est

conçue pour effectuer une tâche spécifique, garantissant une organisation logique et modulaire du backend. L'utilisation de ces endpoints assure que chaque fonctionnalité du système est accessible et peut être manipulée de manière indépendante et sécurisée.

1. Prétraitement des Données

Dans cette section, j'aborde l'importance du prétraitement des données pour notre application du chatbot conversationnel. En décrivant les étapes pour convertir des fichiers PDF en des chunks, ainsi que pour convertir ces chunks en vecteurs numériques. Cette étape initiale revêt une importance capitale, car elle influence directement la qualité et la fiabilité de nos échanges ultérieures. Cette étape initiale, assurée par notre API /upload, revêt une importance capitale pour garantir la qualité et la fiabilité des interactions ultérieures du chatbot. Il convient de souligner que l'API peut traiter les fichiers déjà téléchargés, ce qui évite les répétitions et optimise l'utilisation des ressources.

1.1 Conversion des fichiers PDF en des chunks

Au sein de notre solution, nous avons collecté des documents de tests, tous exclusivement composés de texte et disponibles au format PDF, comme illustré dans la figure




Figure 23 : Extrait d'un document de test

Dans le but d'améliorer les performances et de rendre l'utilisation des documents plus facile, nous avons décidé d'extraire le texte des fichiers PDF. En utilisant la bibliothèque PyPDF2, nous pouvons travailler de manière plus efficace avec les données et les exploiter dans les étapes ultérieures d'analyse et de traitement. Il est crucial de souligner que certains fichiers PDF comportaient des caractères mal formatés, ce qui ajoutait une complexité supplémentaire au processus.

Après l'extraction du texte, nous segmentons ce dernier en morceaux, appelés "chunks", en utilisant « CharacterTextSplitter » de langchain.text_splitter pour découper les textes en petits segments, pour une meilleure précision. Les paramètres définis pour ces chunks incluent une « chunk_size » de 1000

caractères et un « chunk_overlap » de 20 caractères ont été soigneusement choisis après une série de tests et d'analyses pour améliorer la segmentation. Ce chevauchement est essentiel pour assurer que des informations importantes ne soient pas perdues à la jonction des chunks. Cette méthode de segmentation est cruciale pour maintenir l'intégrité du contexte du texte lors des étapes suivantes de traitement et d'analyse des données.

1.2 Conversion des chunks en vecteurs numériques

Lors de l'étape de conversion des chunks en vecteurs numériques, nous avons suivi les étapes suivantes pour effectuer cette transformation :

- **Conversion en vecteurs numériques :** Pour notre projet, nous avons employé la classe ChromaEmbeddingsAdapter de Chroma DB pour transformer chaque section de texte en un vecteur numérique. Notre choix s'est porté sur l'embedding voyage-law, des représentations vectorielles qui capturent avec succès le sens et la signification des mots et des phrases. Grâce à ce embedding, le texte peut être converti en un format exploitable par les algorithmes de traitement automatique du langage naturel, ce qui facilite l'analyse et le traitement ultérieur des données.
- **Stockage des vecteurs numériques :** Nous avons opté pour la classe Chroma de LangChain comme structure de stockage pour gérer et organiser efficacement les vecteurs numériques. La méthode Chroma.from_documents a été employée pour stocker les vecteurs. Cette méthode prend en entrée les textes préalablement segmentés et les embeddings générés par ChromaEmbeddingsAdapter. Un dossier de persistance, nommé "chroma ", a été ajouté pour stocker les vecteurs numériques afin de faciliter leur utilisation future.

Le résultat de cette étape est une collection organisée de vecteurs, comme on peut le voir dans notre base de données chroma.sqlite3. où chaque vecteur est référencé par un embedding_id unique. Cette structure de stockage, optimisée pour les opérations de recherche et de récupération, permet un accès rapide et efficace aux vecteurs. Elle est spécifiquement conçue pour une orientation colonne, facilitant ainsi la manipulation et l'analyse des données vectorielles, cruciales pour notre système de traitement du langage naturel.

L'utilisation de ces vecteurs numériques facilite leur représentation dense et sémantique des textes lors de l'analyse et du traitement des données.

id	key	string_value	int_value	float_value
1	source	D:\DXC-flask\flask\uploads\mostafa\LangChain.pdf		
2	page		0	
3	chroma:document	LangChain Developer(s) Harrison Chase Initial releaseOct...		
4	source	D:\DXC-flask\flask\uploads\mostafa\LangChain.pdf		
5	page		0	
6	chroma:document	contributors on GitHub, trending discussions on Twitter, ...		
7	source	D:\DXC-flask\flask\uploads\mostafa\LangChain.pdf		
8	page		0	
9	chroma:document	cloud storage; API wrappers for news, movie informatio...		
10	source	D:\DXC-flask\flask\uploads\mostafa\LangChain.pdf		
11	page		1	
12	chroma:document	storage; Python RequestsWrapper and other methods fo...		
13	source	D:\DXC-flask\flask\uploads\mostafa\LangChain.pdf		
14	page		1	

Figure 24 : Vector Database (ChromaDB) Metadata

Cette capture d'écran montre les métadonnées stockées dans la base de données vectorielle (ChromaDB) utilisée pour indexer et rechercher des documents. Les tables visibles incluent des informations essentielles telles que les collections, les métadonnées des embeddings, et les configurations de recherche en texte intégral. La table sélectionnée, 'embedding_metadata', montre des détails sur les documents indexés, y compris le chemin d'accès au fichier, les identifiants de page, et les valeurs associées. Ces informations sont cruciales pour le fonctionnement du chatbot, permettant une récupération rapide et précise des informations stockées. Chaque entrée dans la base de données est associée à des identifiants uniques et à des clés spécifiques qui facilitent la recherche et l'extraction de données.

RetrievalQA

Run Feedback Metadata

Input

```

1 query: |+
2 you are a ai assistant This is the summary of
3 the previous conversation. Use it if needed:
4
5 User Question: qui a créer langchain
6
7 Please use all the context provided by the system
  if needed to generate a comprehensive and accurate
  response and display it. Answer primarily in
  French, but if the question is in another language,
  answer in that language.if the user ask a question
  that not relate to artificial intelligence or the
  context provided dont answer

```

YAML

Rendered Output

LangChain a été créé par Harrison Chase en octobre 2022 en tant que

START TIME: 08/29/2024, 01:12:01 PM
 END TIME: 08/29/2024, 01:12:05 PM
 TIME TO FIRST TOKEN: N/A
 STATUS: Success
 TOTAL TOKENS: 6,397 tokens / \$0.0033475
 LATENCY: 3.50s

Figure 25 : LLMChain and RetrievalQA Execution Trace

Cette capture d'écran montre l'interface de suivi des exécutions pour les chaînes LLMChain et RetrievalQA dans le cadre du projet DXC Rag final. L'image capture une session de questions-réponses où l'utilisateur a posé une question, et le modèle a généré une réponse en utilisant le contexte fourni. Le temps d'exécution pour chaque composant de la chaîne est également visible, y compris le temps pris par le récupérateur et le modèle GPT-3.5-turbo pour répondre à la requête. Les détails supplémentaires incluent le statut de l'exécution (succès), le nombre total de jetons utilisés, et la latence globale. Cet outil est essentiel pour surveiller les performances des modèles en temps réel et pour affiner les configurations en fonction des résultats observés.




Figure 26 : Retriever Execution and Document List

Cette capture d'écran montre les détails de l'exécution du composant Retriever utilisé dans le projet DXC Rag final. L'interface affiche les documents que le Retriever a consultés pour générer la réponse. Chaque document est listé avec son titre et des indicateurs montrant le nombre de fois qu'il a été consulté ou utilisé dans le processus de récupération. Les tags utilisés pour cette exécution sont également visibles. L'image met en évidence la manière dont les documents sont extraits et triés, ce qui permet d'assurer que les informations les plus pertinentes sont accessibles rapidement. Cette vue est essentielle pour comprendre le fonctionnement interne de la récupération d'informations et pour ajuster le processus en fonction des résultats observés.




Figure 27 : ChatOpenAI Execution Trace

Cette capture d'écran montre l'exécution de ChatOpenAI dans le projet DXC Rag final. L'image capture le flux complet de la requête, incluant le passage par le module RetrievalQA, puis le retriever, et enfin le modèle GPT-3.5-turbo. Le texte de la question posée par l'utilisateur ainsi que la réponse générée sont également affichés.

Le rendu de la réponse finale est visible sous la section 'Rendered Output', ce qui montre comment le modèle traite et formate la réponse basée sur le contexte fourni. Cette vue est essentielle pour comprendre comment les modules d'intelligence artificielle travaillent ensemble pour fournir des réponses complètes et précises aux utilisateurs.

III. 2. Frontend - Application Desktop (Tkinter)




Figure 28 : Écran de Connexion de l'Application Desktop

Cet écran représente l'interface de connexion de l'application desktop développée avec Tkinter. Il permet aux utilisateurs de se connecter en saisissant leur nom d'utilisateur et leur mot de passe. L'interface est conçue de manière à être simple et intuitive, avec des champs de saisie clairement identifiés et des boutons bien visibles pour se connecter ou s'inscrire. Les utilisateurs peuvent également naviguer entre différentes options grâce à une interface propre et épurée, rendant la connexion facile et accessible.




Figure 29 : Écran Principal de l'Application Desktop

L'écran principal de l'application desktop permet aux utilisateurs de visualiser des documents PDF, de les télécharger, et d'interagir avec un chatbot. Les fichiers PDF téléchargés sont stockés et indexés dans une base de données vectorielle, rendant le système capable de fournir des réponses précises basées sur le contenu des documents. L'interface utilisateur est optimisée pour faciliter l'accès aux fonctionnalités principales, offrant une expérience utilisateur fluide et intuitive.




Figure 30 : Écran de Confirmation de Téléchargement

Cet écran apparaît après qu'un utilisateur a téléchargé un fichier PDF et confirme que l'opération s'est déroulée avec succès. L'utilisateur est informé par une fenêtre contextuelle que le fichier a été téléchargé et traité, ce qui améliore l'expérience utilisateur en fournissant un retour immédiat. Cela garantit que les utilisateurs savent que leurs actions ont été prises en compte par le système, renforçant ainsi la confiance dans l'application.

IV. 3. Frontend - Application Web (React)




Figure 31 : Écran de Connexion de l'Application Web

Cet écran représente la page de connexion de l'application web, où les utilisateurs peuvent se connecter en utilisant leur nom d'utilisateur et mot de passe. L'interface est moderne et fonctionnelle, avec une image de fond dynamique et des boutons pour se connecter via des comptes de réseaux sociaux. Chaque bouton est clair et bien positionné, facilitant la navigation et l'interaction pour les utilisateurs, qu'ils soient novices ou expérimentés.




Figure 32 : Écran de Création de Compte de l'Application Web

Cet écran permet aux nouveaux utilisateurs de créer un compte pour accéder à l'application. L'interface est conçue pour être simple et intuitive, avec des champs de saisie pour le nom d'utilisateur et le mot de passe, ainsi que des options pour s'inscrire via des réseaux sociaux. Les boutons sont bien

visibles et permettent une navigation fluide, tandis que les utilisateurs peuvent facilement revenir à la page de connexion si nécessaire.




Figure 33 : Écran d'Accueil de l'Application Web

La page d'accueil de l'application web introduit l'utilisateur au concept de RAG (Retrieval-Augmented Generation) et lui permet de commencer à interagir avec le chatbot. L'interface est épurée et informative, expliquant le fonctionnement du système et présentant un diagramme illustratif. Les utilisateurs peuvent accéder facilement aux fonctionnalités principales, et le design assure une expérience utilisateur claire et engageante.




Figure 34 : Écran de Gestion des PDF avec OCR (Application Desktop)

Cet écran permet aux utilisateurs de gérer leurs fichiers PDF et d'extraire du texte via OCR. L'interface permet de rechercher, visualiser, et éditer des documents PDF, rendant l'application puissante et polyvalente. Les boutons d'action offrent des options claires pour la manipulation des documents, améliorant ainsi l'efficacité des utilisateurs dans leurs tâches quotidiennes.




Figure 35 : Écran de Téléchargement de PDF ou Texte avec Indicateur de Chargement (Application Web)

Cet écran montre le processus de téléchargement d'un fichier PDF ou d'un texte, avec un indicateur de chargement en cours. Une fois le téléchargement terminé, une fenêtre contextuelle informe l'utilisateur que l'opération a été effectuée avec succès. L'interface assure que les utilisateurs restent informés tout au long du processus, améliorant la transparence et l'efficacité du système.



Figure 36 : Écran d'Interaction avec le Chatbot (Application Web)

Cet écran montre l'interface de chat où l'utilisateur peut interagir avec le chatbot tout en consultant un PDF. L'interface est divisée entre la visualisation du document et la conversation, offrant une expérience utilisateur intégrée et fluide. Les boutons de navigation et d'envoi de message sont bien positionnés, permettant une interaction facile et rapide avec le chatbot.




Figure 37 : Écran de Navigation et Extraction OCR du PDF (Application Web)

Cet écran permet aux utilisateurs de naviguer dans un document PDF et d'extraire du texte via OCR. L'interface comprend des options pour la pagination, la manipulation du PDF, et l'extraction de texte, rendant la gestion des documents simple et efficace. Les utilisateurs peuvent facilement naviguer entre les pages et extraire le texte nécessaire en quelques clics.

V. Conclusion

En conclusion, La réalisation du projet DXC Rag Chatbot a permis de concrétiser les concepts théoriques et les spécifications techniques définis lors des phases précédentes. À travers le développement des différents composants du système, nous avons pu implémenter une solution robuste et performante pour la gestion et l'interaction avec des documents via un chatbot alimenté par un modèle d'intelligence artificielle.

Chaque étape du processus de réalisation a été soigneusement exécutée, de la création de l'infrastructure backend à la mise en place des interfaces frontend. L'utilisation de technologies modernes, telles que Flask pour le backend, ChromaDB pour la gestion des données vectorielles, et React pour le frontend, a été essentielle pour atteindre les objectifs du projet.

L'intégration des différents modules, qu'il s'agisse de l'authentification des utilisateurs, du stockage des documents, ou de l'exécution des modèles d'intelligence artificielle, a abouti à une application complète qui répond aux besoins spécifiques des utilisateurs en matière de recherche d'information et de génération de réponses contextuelles.

En somme, la réalisation de ce projet démontre non seulement la faisabilité technique du concept proposé, mais aussi sa capacité à fournir une expérience utilisateur fluide, intuitive, et efficace. Les résultats obtenus lors des tests et des démonstrations montrent que le système est prêt à être déployé dans un environnement réel, où il pourra offrir ses fonctionnalités à un large éventail d'utilisateurs.

Conclusion Générale

Dans le cadre de notre projet de fin d'études, nous avons conçu et développé une application de chatbot pour la communication interactive avec des fichiers PDF, destinée à l'entité utilisatrice de notre entreprise. Ce document décrit en détail toutes les étapes que nous avons suivies pour atteindre le résultat attendu. Au cours de notre travail, nous avons élaboré notre solution progressivement en utilisant le processus Scrum, en utilisant des techniques et des formalismes externes éprouvés. Nous avons entamé par comprendre le contexte général de notre application et repérer ses différentes exigences. Ensuite, nous avons établi notre planning de travail en mettant l'accent sur les besoins ayant la plus grande valeur métier ajoutée. Une fois le planning établi, nous avons débuté l'analyse, la conception et l'implémentation de chaque sprint dans l'ordre prévu. Une section finale est dédiée à l'évaluation et tests. Malgré les contraintes de temps et les difficultés techniques, principalement dues à l'appropriation de nouvelles technologies, nous avons réussi à réaliser la première version de notre solution.

Le travail dans le cadre de ce PFE, était d'une importance considérable dans la mesure où il nous a servi comme portail vers le monde professionnel et la vie d'entreprise. De point de vue technique, il nous a permis de mettre en œuvre les acquis théoriques que nous avons appris tout au long de notre cursus universitaire et de les enrichir et approfondir de techniques relevant du domaine de l'intelligence artificielle. De surcroît, ce projet nous a été une opportunité de mise en pratique de la gestion de projet par le Framework Scrum. Ainsi, j'ai eu l'opportunité de bénéficier de différentes certifications.

En termes de perspectives, les résultats obtenus et les compétences acquises ouvrent de nombreuses opportunités. Le chatbot créé spécifiquement pour être utilisé dans d'autres organismes. En outre, les compétences techniques développées dans ce projet peuvent être appliquées dans d'autres secteurs, comme le service client et la santé.

En conclusion, ce stage a été une expérience enrichissante et formatrice. Les connaissances que nous avons acquises, aussi bien sur le plan technique que personnel, sont une base solide pour notre avenir professionnel. Nous sommes enthousiastes à l'idée d'explorer de nouvelles perspectives et de continuer à participer à la création de solutions innovantes dans le domaine de l'informatique et de l'intelligence artificielle.

Annexe


I. Annexe1 : modèle OcR

- **Introduction au CNN**

Les réseaux de neurones convolutifs (CNN) sont une classe de réseaux de neurones profonds spécialement conçus pour traiter les données structurées sous forme de grilles, comme les images. Ils sont largement utilisés dans la vision par ordinateur pour des tâches telles que la classification d'images, la détection d'objets, et bien sûr, la reconnaissance optique de caractères (OCR). Les CNN se distinguent par leur capacité à capturer des caractéristiques spatiales locales à l'aide de filtres de convolution, et à les combiner de manière hiérarchique pour former des représentations plus abstraites.

- **Dataset**

Le dataset utilisé pour entraîner le modèle de reconnaissance de caractères (OCR) contient un total de 20 628 images réparties en 36 classes, correspondant aux chiffres (0-9) et aux lettres (A-Z). Chaque classe est représentée par un dossier contenant des images associées à ce caractère spécifique. Les images ont été redimensionnées à 64x64 pixels et normalisées pour être utilisées comme entrée dans le modèle.



- **Prétraitement**

Avant d'entraîner le modèle, les images du dataset ont été soumises à un prétraitement. Chaque image a été redimensionnée à 64x64 pixels, convertie en un tableau numpy, et normalisée pour que les valeurs de pixels soient comprises entre 0 et 1. De plus, les étiquettes de caractères ont été encodées en valeurs numériques à l'aide de la classe LabelEncoder de scikit-learn. Enfin, pour éviter tout biais lors de l'entraînement, les données ont été mélangées de manière aléatoire.

```

path = '/kaggle/input/standard-ocr-dataset/data/training_data'
dir_list = os.listdir(path)
for i in dir_list:
    dir = os.path.join(path, i)
    file_list = os.listdir(dir)
    for j in file_list:
        files = os.path.join(dir, j)
        img = cv2.imread(files)
        img = cv2.resize(img, (64,64))
        img = np.array(img, dtype=np.float32)
        img = img/255
        images.append(img)
        labels.append(i)
plt.imshow(images[0])
plt.title(f"Label: {labels[0]}")
plt.show()
X = np.array(images)
y = np.array(labels)
X.shape
le = LabelEncoder()
y = le.fit_transform(y)
len(set(y))
X_sh, y_sh = shuffle(X, y, random_state=42)

```

• Mon CNN

Le modèle CNN utilisé est constitué de plusieurs couches convolutives suivies de couches de pooling, de couches denses, et d'une couche de sortie avec activation softmax. Ce modèle a été entraîné sur le dataset prétraité pour reconnaître les caractères alphanumériques.

```


model = Sequential()

model.add(Conv2D(filters=16, kernel_size=(3,3), activation='relu', input_shape=(64,64,3)))
model.add(MaxPooling2D())
model.add(Conv2D(filters=32, kernel_size=(3,3), activation='relu'))
model.add(MaxPooling2D())
model.add(Conv2D(filters=64, kernel_size=(3,3), activation='relu'))
model.add(MaxPooling2D())
model.add(Conv2D(filters=128, kernel_size=(3,3), activation='relu'))
model.add(Flatten())
model.add(Dense(units=128, activation='relu'))
model.add(Dense(units=64, activation='relu'))
model.add(Dense(units=36, activation='softmax'))

```

• Évolution de l'Accuracy du Modèle

Le graphique ci-dessous montre l'évolution de l'accuracy du modèle CNN au fil des époques d'entraînement. On peut observer une amélioration continue de l'accuracy avec l'augmentation du nombre d'époques.



Références

LangChain. LangChain, [en ligne]. Disponible sur : www.docs.langchain.com/docs. (consulté le 13 Avril 2024)

LangChain. Get started, [en ligne]. Disponible sur : www.python.langchain.com. (consulté le 08 Avril 2024)

Openai. Welcome to the OpenAI platform, [en ligne]. Disponible sur : www.platform.openai.com. (consulté le 14 Avril 2024)

Chroma. Chroma, [en ligne]. Disponible sur : www.docs.trychroma.com (consulté le 15 Mai 2024)

MyScale. Prompt engineering vs. finetuning vs. RAG. [en ligne]. Disponible sur : <https://myscale.com/blog/prompt-engineering-vs-finetuning-vs-rag/>. (consulté le 4 juin 2024)

[1] Méthodologie Agile, Disponible sur : <https://www.tuleap.org/agile/agile-scrum-in-10-minutes>.

[2] Documentation DXC Technology Maroc, Disponible sur : <https://www.dxc-maroc.com/>

Formations suivies :

[1] : Marco, E. LangChain - Develop LLM powered applications with LangChain. Learn LangChain by building FAST a real-world generative AI LLM powered application [en ligne]. Disponible sur : www.udemy.com/course/langchain-develop-llm-powered-applications . (consulté le 12 avril 2024)